

BAŞLIK: FEATURE ENGINEERING (ÖZELLİK MÜHENDİSLİĞİ): GENEL TEKRAR SORULARI

TÜR: Çoktan Seçmeli Değerlendirme (Sorular 12.1 - 12.4 konularını kapsar)

SORULARIN CEVAPLARI EN ALTTA BULUNMAKTADIR.

1. Aykırı değerlerin doğrusal regresyon gibi modeller üzerindeki etkisi neden ağaç tabanlı modellere göre daha büyüktür?

- A) Ağaç modelleri sadece kategorik verilerle çalışır.
- B) Ağaç modelleri hiç veri kullanmaz.
- C) Doğrusal modeller tüm veri noktalarının etkisini matematiksel formüle dahil eder, ağaç modelleri ise bölünmelerde medyan/eşik tabanlı çalıştığı için daha az etkilenir.
- D) Doğrusal modeller aykırı değerleri otomatik siler.

2. IQR (Interquartile Range) yöntemiyle üst aykırı değer eşiği nasıl hesaplanır?

- A) $Q3 + 1.5 * IQR$
- B) $Q1 - 1.5 * IQR$
- C) $Medyan * 1.5$
- D) $Ortalama + 2 * Standart Sapma$

3. IQR yönteminin ortalama tabanlı yöntemlere (standart sapma yaklaşımı) göre avantajı nedir?

- A) Sadece kategorik verilerde çalışması.
- B) Hiçbir avantajı yoktur.
- C) Çeyreklik değerlere (medyan tabanlı) dayandığı için aykırı değerlerin kendisinden daha az etkilenmesi.
- D) Daha hızlı hesaplanması.

4. Z-Skoru yaklaşımında bir değerın aykırı kabul edilmesi için genel kabul gören aralık nedir?

- A) -1 ile +1 arası dışı
- B) -2.5 ile +2.5 arası dışı
- C) 0 ile 10 arası dışı
- D) Sadece pozitif değerler

5. Çok değişkenli (multivariate) aykırı değer tespiti için hangi yöntem tercih edilir?

- A) Sadece ortalama alma
- B) Sadece IQR yöntemi
- C) Label Encoding
- D) LOF (Local Outlier Factor)

6. Bir değişkendeki eksikliğin 'rastgele' olup olmadığını incelemek neden önemlidir?

- A) Eksiklik hiçbir zaman rastgele olamaz.

- B) Sadece görsel amaçlıdır.
- C) Önemli değildir, her zaman silinebilir.
- D) Eksiklik rastgele değilse (başka bir değişkene bağlıysa), silme/doldurma işlemleri ciddi yanlışlıklara (bias) yol açabilir.

7. 'Kredi kartı yoksa kredi kartı harcaması NA olur' örneği hangi kavramı açıklar?

- A) Bir değişkendeki eksikliğin başka bir değişkenin durumuna bağlı (yapısal) olarak ortaya çıkması.
- B) Ölçüm hatası.
- C) Tamamen rastgele eksiklik.
- D) Veri girişi hatası.

8. Eksik değerlerle başa çıkmak için bahsedilen 3 ana yaklaşım nedir?

- A) Sadece ortalama ile doldurma.
- B) Veriyi görmezden gelme.
- C) Sadece silme.
- D) Silme, Değer Atama (mod/medyan), Tahmine Dayalı Yöntemler.

9. Eksik veriyi doğrudan silmenin güvenilir olabilmesi için hangi koşul sağlanmalıdır?

- A) Değişkenin sayısal olması.
- B) Eksikliğin (kısmen veya tamamen) rastlantısal olarak oluşmuş olması.
- C) Eksikliğin veri setinin büyük çoğunluğunu kapsaması.
- D) Hiçbir koşula gerek yoktur, her zaman silinebilir.

10. Label Encoding, sınıflar arasında doğal bir sıralama (ordinal) olan bir değişkende (örn. eğitim seviyesi) kullanıldığında neden uygundur?

- A) Çünkü hiçbir zaman uygun değildir.
- B) Çünkü Label Encoding sadece ordinal değişkenlerde çalışabilir.
- C) Çünkü One-Hot Encoding hiç kullanılamaz.
- D) Çünkü sayısal temsildeki büyüklük-küçüklük ilişkisi (0,1,2...), değişkenin gerçek sıralı yapısıyla örtüşür.

11. Label Encoding'i nominal (sıralı olmayan, örn. futbol takımları) bir değişkende kullanmanın riski nedir?

- A) Hiçbir risk yoktur.
- B) Verinin sayısallaşamaması.
- C) Modelin, aslında var olmayan bir büyüklük/sıralama ilişkisini (örn. bir takımın diğerinden 'büyük' olduğunu) öğrenmeye çalışması.
- D) Sadece hesaplama hızını etkilemesi.

12. One Hot Encoding, nominal bir değişkeni nasıl dönüştürür?

- A) Her sınıfa 0'dan başlayan bir sayı atayarak.
- B) Sınıfları alfabetik sıraya göre numaralandırarak.

- C) Her sınıf için ayrı bir sütun oluşturup, gözlem o sınıfa aitse 1 diğer sütunlarda 0 vererek.
D) Tüm sınıfları tek bir sütunda birleştirerek.

13. Dummy Variable Trap (Kukla Değişken Tuzağı) nasıl oluşur ve nasıl önlenir?

- A) Sadece sayısal değişkenlerde görülür.
B) One Hot Encoding sonrası tüm sütunlar modele dahil edildiğinde sütunlar arası tam doğrusal bağımlılık (multicollinearity) oluşur; bir sütunun (drop_first) çıkarılmasıyla önlenir.
C) Label Encoding kullanıldığında oluşur ve hiçbir şekilde önlenemez.
D) Rare Encoding uygulanınca otomatik oluşur.

14. Rare Encoding'de bir sınıfın 'nadir' (rare) sayılması için hangi kriter kullanılır?

- A) Sınıfın veri setindeki oranının belirlenen bir eşik (örn. %1) değerinden düşük olması.
B) Sınıfın alfabetik sırası.
C) Sınıfın sayısal olması.
D) Sınıfın ismi uzun ise.

15. Rare Encoding'in One-Hot Encoding'den önce uygulanmasının pratik nedeni nedir?

- A) Önce nadir sınıflar birleştirilmezse, One-Hot Encoding her nadir sınıf için ayrı ve neredeyse boş sütunlar üreterek veri setini gereksiz şişirir.
B) Sırası önemli değildir.
C) Rare Encoding One-Hot Encoding'i tamamen gereksiz kılar.
D) One-Hot Encoding sadece Rare Encoding'den sonra çalışabilir.

16. Feature Scaling'in mesafe tabanlı algoritmalar (KNN, K-Means, SVM) için gerekli olmasının nedeni nedir?

- A) Sadece görsel amaçlıdır.
B) Bu algoritmalar ölçekten hiç etkilenmez.
C) Farklı büyüklükteki değişkenler (örn. maaş vs yaş) arasındaki mesafe hesaplamasında büyük ölçekli değişken diğerini gölgede bırakır.
D) Sadece kategorik değişkenler için gereklidir.

17. Standardization (Z-Score) formülü nedir ve sonucu neyi ifade eder?

- A) $X / X_{\max}$; veriyi -1 ile 1 arasına sıkıştırır.
B) $(X - \text{Medyan}) / \text{IQR}$; medyan tabanlı ölçekleme yapar.
C) $(X - X_{\min}) / (X_{\max} - X_{\min})$; veriyi 0-1 arasına sıkıştırır.
D) $(x - \text{ortalama}) / \text{standart sapma}$; ortalaması 0, standart sapması 1 olan bir dağılım üretir.

18. Veri setinde çok fazla aykırı değer varken hangi ölçeklendirme yöntemi tercih edilmelidir ve neden?

- A) Robust Scaler, çünkü ortalama yerine medyan ve IQR kullandığı için aykırı değerlerden daha az etkilenir.
B) Min-Max Scaler, çünkü her zaman en iyisidir.

- C) Hiçbiri, ölçeklendirme yapılmamalıdır.
- D) Standardization, çünkü aykırı değerleri tamamen yok sayar.

19. Ağaç tabanlı modellerde (Random Forest, XGBoost) Feature Scaling yapmak neden genelde gerekli değildir?

- A) Çünkü bu modeller veriyi hiç kullanmaz.
- B) Çünkü bu modeller bölünme kararlarını sayıların büyüklüğüne değil, eşik/kural tabanlı karşılaştırmalara göre verir.
- C) Çünkü bu modeller sadece kategorik veri kabul eder.
- D) Çünkü scaling bu modellerde hataya yol açar.

20. Feature Extraction (Özellik Çıkarımı) temel olarak neyi ifade eder?

- A) Modelin hiperparametrelerini ayarlamak.
- B) Ham veriden (yapısal veya yapısal olmayan) yeni, anlamlı değişkenler türetmek.
- C) Sadece veri setini küçültmek.
- D) Var olan sütunları silmek.

21. Bir zaman damgasından (timestamp) 'Hafta Sonu mu?' gibi bir özellik türetmenin amacı nedir?

- A) Sadece görsel amaçlıdır.
- B) Veriyi karmaşıktırmak.
- C) Zaman damgasını tamamen silmek.
- D) İnsan davranışının hafta içi/hafta sonu farklılık gösterebileceği bilgisini modelin doğrudan kullanabileceği bir forma getirmek.

22. Metin verisinden 'Noktalama İşareti Sayısı' veya 'Harf Uzunluğu' gibi özellikler çıkarmanın mantığı nedir?

- A) Metni şifrelemek.
- B) Metnin duygusal yoğunluğu veya ciddiyeti hakkında dolaylı sayısal ipuçları elde etmek.
- C) Metni tamamen anlamsız hale getirmek.
- D) Sadece yazım hatalarını bulmak.

23. Bir film önerisi sisteminde film özetini (plot) TF-IDF ile vektörleştirmenin amacı nedir?

- A) Filmin bütçesini tahmin etmek.
- B) Oyuncu isimlerini silmek.
- C) Metni, benzer temalı diğer filmlerle karşılaştırılabilecek matematiksel bir forma (vektöre) dönüştürmek.
- D) Filmin süresini hesaplamak.

24. 'Metrekare Başına Fiyat' gibi türetilmiş bir özellik, yapısal veriden özellik türetmenin hangi türüne örnektir?

- A) Var olan sayısal sütunları matematiksel olarak birleştirip daha anlamlı yeni bir bilgi üretme (yapısal veriden türetme).
- B) Yapısal olmayan veriden türetme.

C) Görüntü işleme.

D) Ses analizi.

CEVAP ANAHTARI

1-C 2-A 3-C 4-B 5-D 6-D 7-A 8-D 9-B 10-D 11-C 12-C 13-B 14-A 15-A 16-C 17-D 18-A 19-B 20-B
21-D 22-B 23-C 24-A