

Modül 2: Agregasyon ve Gruplama (Aggregations & Grouping)

Veri biliminde milyonlarca satır veriyi tek tek inceleyemeyiz. Veriyi anlamlandırmak için onu özetlememiz (aggregate) ve belirli kategorilere göre gruplandırmamız gerekir.

2.1. Temel Agregasyon Fonksiyonları (The Big 5)

Bu fonksiyonlar, bir sütundaki tüm değerleri alıp tek bir sonuç (istatistik) üretir.

- **COUNT():** Satırları veya değerleri sayar.
 - **COUNT(*):** NULL değerler dahil tüm satırları sayar.
 - **COUNT(sutun_adi):** Sadece NULL olmayan değerleri sayar.
- **SUM():** Sayısal sütunların toplamını alır.
- **AVG():** Sayısal sütunların ortalamasını hesaplar.
- **MIN() / MAX():** Bir sütundaki en küçük ve en büyük değeri bulur (Sayı, metin veya tarih için çalışır).

Örnek Sorgu:

```
SELECT
    COUNT(*) AS toplam_satis_adi,
    AVG(fiyat) AS ortalama_fiyat,
    MAX(fiyat) AS en_pahalı_urun
FROM satislar;
```

2.2. Veriyi Segmentlere Ayırma: GROUP BY

GROUP BY, veriyi belirli bir sütundaki değerlere göre "kovalara" (buckets) ayırır. Agregasyon fonksiyonları genellikle bu gruplar üzerinde çalışır.

Kritik Kural: SELECT kısmında bir agregasyon fonksiyonu (SUM, AVG vb.) kullanıyorsanız, yanında yer alan tüm yalın sütunları GROUP BY kısmına yazmak zorundasınız.

Örnek Sorgu:

```
SELECT
    kategori,
    şehir,
    SUM(satis_tutari) AS toplam_ciro
FROM satislar
GROUP BY kategori, şehir; -- Veriyi önce kategoriye, sonra şehre göre böler.
```

2.3. Gruplanmış Veriyi Filtreleme: HAVING

Veri biliminde en çok karıştırılan konulardan biri WHERE ve HAVING farkıdır.

- **WHERE:** Veri henüz gruplanmadan önce, ham satırlar üzerinde filtreleme yapar.
- **HAVING:** Veri gruplandıktan ve agregasyon (SUM, AVG vb.) hesaplandıktan sonra, **oluşan sonuçlar** üzerinde filtreleme yapar.

Örnek Sorgu:

```
SELECT kategori, AVG(fiyat) AS ort_fiyat
FROM urunler
WHERE stok_durumu = 'Mevcut' -- Önce stokta olanları seç (Ham veri filtresi)
GROUP BY kategori
HAVING AVG(fiyat) > 500;      -- Sonra ortalaması 500'den büyük olan grupları getir.
```

2.4. Veri Bilimi İçin Derinlemesine Detaylar

A. COUNT(DISTINCT): "Unique" Sayıları Bulma

Veri biliminde "Kaç farklı müşteri alışveriş yaptı?" veya "Kaç farklı şehirden veri geldi?" gibi soruların cevabıdır.

```
SELECT kategori, COUNT(DISTINCT muster_id) AS tekil_musteri_sayisi
FROM satislar
GROUP BY kategori;
```

B. Agregasyonlarda NULL Yönetimi

Agregasyon fonksiyonları (COUNT(*)) hariç **NULL değerleri görmezden gelir**.

- AVG(puan) hesaplanırken, puanı NULL olan satırlar payda kısmına (adet) dahil edilmez. Bu, bazen istatistiksel sapmalara yol açabilir.

C. Matematiksel İfadelerle Gruplama

Sadece sütun ismine göre değil, bir hesaplama göre de gruplama yapabilirsiniz.

```
-- Satış tarihindeki yılı çekip yıla göre gruplama
SELECT EXTRACT(YEAR FROM satis_tarihi) AS yil, SUM(tutar)
FROM satislar
GROUP BY EXTRACT(YEAR FROM satis_tarihi);
```

2.5. SQL Çalışma Sırası Hatırlatması (Modül 2 Eki)

Modül 1'de gördüğümüz çalışma sırasına bu modülün kavramlarını yerleştirelim:

1. **FROM / JOIN** (Nereden?)
2. **WHERE** (Ham veri filtresi)
3. **GROUP BY** (Gruplandırma)
4. **HAVING** (Grup filtresi)
5. **SELECT** (Sütun seçimi ve Agregasyon hesaplaması)
6. **ORDER BY** (Sıralama)

Veri Bilimcisi Notu: Eğer bir sorguda AVG veya SUM gibi bir değer üzerinden filtreleme yapmanız gerekiyorsa (HAVING), bunu asla WHERE içinde yapamazsınız çünkü SQL o aşamada henüz toplamı veya ortalamayı hesaplamamıştır.

2.6. Meydan Okuma

"Soru: Bir e-ticaret sitesinde, 2023 yılında 5'ten fazla sipariş vermiş olan müşterilerin toplam harcamasını listeleyen sorguyu yazın."