

Ağırlıklı Ortalama (Weighted Average) ve Sezgisel Modelleme

Zaman serisi analizinde basit hareketli ortalamanın (Moving Average) en büyük eksikliği, tüm geçmiş verilere eşit önem vermesidir. **Ağırlıklı Ortalama**, "gelecek, yakın geçmişe daha çok benzer" ilkesinden yola çıkarak bu sorunu çözer.

1. Temel Mantık: Yakın Veriye Öncelik

Ağırlıklı ortalama, tahmin edilecek noktaya en yakın olan gözlemlere daha yüksek katsayılar (ağırlıklar) verilir. Bu sayede model, verideki güncel değişimlere ve trendlere karşı çok daha duyarlı hale gelir.

2. Hareketli Ortalama vs. Ağırlıklı Ortalama (Vaka Analizi)

Transkriptteki reklam izlenme verileri üzerinden yapılan karşılaştırma, ağırlıklandırmanın gücünü net bir şekilde ortaya koymaktadır:

- Gerçek Değer:** 82.285 (Tahmin edilmeye çalışılan değer)
- Senaryo:** Son 3 gözlem üzerinden tahmin yapılması.

Yöntem	Hesaplama Mantığı	Tahmin Sonucu	Gerçek Değere Yakınlık
Hareketli Ortalama	$(\text{Değer 1} + \text{Değer 2} + \text{Değer 3}) / 3$	107.210	+24.925 hata payı
Ağırlıklı Ortalama	$(60\% * \text{Son Değer}) + (30\% * \text{Önceki}) + (10\% * \text{Daha Önceki})$	100.356	+18.071 hata payı

Sonuç: Sadece basit bir ağırlıklandırma bile, tahmini gerçek değere **yaklaşık 7.000 birim** daha yaklaştırmıştır.

3. Saf Mantıkla Modelleme: "Amazon Satıcısı" Örneği

Karmaşık algoritmalar bilmeden de bir zaman serisi problemi, "yüzdelik değişimler" üzerinden manuel olarak modellenebilir. Bir veri bilimcinin yaptığı şey aslında şu faktörleri matematiksel olarak birleştirmektir:

- **Mevsimsellik:** Hafta içinden hafta sonuna geçişteki %'lik değişim.
 - **Trend:** Satışlardaki genel büyüme ivmesi (%'lik artış).
 - **Dışsal Faktörler:** Yeni eklenen ürünlerin veya reklamların satışa etkisi.
-

4. Neden Hala "Mükemmel" Değiliz?

Ağırlıklı ortalama, hareketli ortalamaya göre daha başarılı olsa da şu iki yapısal engel karşısında zorlanır:

1. **Trend:** Veri sürekli bir eğimle düşüyor veya yükseliyorsa, sadece son değerlere ağırlık vermek hala yeterli bir "takip" sağlamayabilir.
2. **Mevsimsellik:** Eğer veri döngüsel bir yapıdaysa, sadece "en son değerlere" bakmak, geçmişteki periyodik desenleri (hafızayı) unutmamıza neden olur.

Kritik Kazanım

Bir zaman serisi gördüğümüzde artık şunları yapabiliyoruz:

- **Trendi** yorumlayabiliyoruz (Artış/Azalış).
 - **Mevsimselliği** görebiliyoruz (Tekrarlanan desenler).
 - **Durağanlığı** kısmen saptayabiliyoruz.
 - En önemlisi; gelişmiş teknikler bilmesek bile "**Ağırlıklı Ortalama + Değişim Yüzdesi**" mantığıyla profesyonel seviyeye yakın projeksiyonlar yapabiliyoruz.
-

5. Smoothing (Düzeltilme) Yöntemlerine Geçiş

Ağırlıklı ortalama mantığını bir adım öteye taşıyıp, bu ağırlıklandırma işlemini tüm geçmiş kapsayacak şekilde "üstsel" (exponential) olarak yapan yöntemlere geçeceğiz. Bu yöntemler (SES, DES, TES), ağırlıkları bizim manuel vermemize gerek kalmadan, optimizasyon ile kendi belirleyecektir.