

Üretken yapay zeka ve büyük dil modelleri (LLM) dünyasına adım attığınızda, kendinizi yepyeni bir dilin konuşulduğu yabancı bir ülkede gibi hissedebilirsiniz. Bu alanda başarılı uygulamalar geliştirmek için sadece kod yazmayı bilmek yetmez; sistemin temel taşlarını oluşturan kavramlara da hakim olmak gerekir.

İşte uygulama geliştirme sürecinde karşınıza en sık çıkacak, LLM dünyasının "temel sözlüğü" diyebileceğimiz kritik kavramlar:

1. Prompt (Girdi) ve Completion (Tamamlama)

Her etkileşimin bir başlangıcı ve bir sonucu vardır.

- **Prompt:** Modele gönderdiğimiz her türlü metin, talimat veya soruya verilen isimdir. Teknik olarak bu, Transformer mimarisine sunduğumuz "girdi dizisi"dir.
- **Completion:** Modelin bu girdiyi işledikten sonra ürettiği yanıttır. Model aslında kendisine verilen metni "tamamlamaya" çalıştığı için bu terim kullanılır.

2. Token (Jeton): Yapay Zekanın Para Birimi

Modeller metinleri doğrudan harf harf veya kelime kelime okumazlar. Metni, **Token** adı verilen daha küçük parçalara ayırırlar. Bir token bazen bir kelimenin tamamı, bazen sadece bir hece, bazen de bir noktalama işaretidir.

Tokenları yapay zekanın "işlem birimleri" veya "paraları" gibi düşünebilirsiniz. Hem maliyet hesaplamaları hem de modelin kapasite sınırları bu birim üzerinden belirlenir.

3. Stream (Akış): Yanıtın İlmek İlmek İşlenmesi

ChatGPT gibi servislerde yanıtın tek seferde değil, kelime kelime (aslında token token) ekrana aktığını görürsünüz. Bu bir görsel efekt değildir. Model, her seferinde bir sonraki token'ı tahmin ederek ilerlediği için yanıtı parça parça üretir. Bu sürece **Streaming** diyoruz. Klasik API'lerin aksine, yanıtın tamamlanmasını beklemeden gelen parçaları kullanıcıya göstermemize olanak tanır.

4. Parametre: Modelin Zeka Kapasitesi

Bir modelin "ne kadar büyük" veya "ne kadar yetenekli" olduğunu anlamak için kullanılan en temel ölçüt parametre sayısıdır. Parametreler, modelin eğitim sırasında öğrendiği milyarlarca küçük ayar ve bağlantıdır. Genellikle parametre sayısı arttıkça modelin

muhakeme yeteneđi ve bilgi birikimi de artar; ancak bu, işlem gücü ihtiyacını da beraberinde getirir.

5. Knowledge Cutoff (Son Güncel Bilgi Tarihi)

Dil modelleri internete her an bađlı, her şeyi anlık öğrenen yapılar deđildir. Eğitim süreçleri aylar sürdüğü için her modelin bir "bilgi kesilme tarihi" vardır. Eğer modelin eğitim verisi 2024 sonunda bitiyorsa, 2025'te olan bir olay hakkında -harici bir kaynak sunulmadıkça- bilgi sahibi olamaz. Bu kısıtı bilmek, uygulamanızın sınırlarını belirlemek açısından kritiktir.

6. Context Window (Bađlam Penceresi)

Bađlam penceresi, bir modelin tek bir oturumda aklında tutabileceđi toplam token sınırıdır. Bunu modelin **kısa süreli belleđi** olarak düşünebilirsiniz.

Önemli Not: Bađlam penceresi hem gönderdiğiniz prompt'u hem de modelin ürettiđi completion'ı kapsar. Bu pencere dolduğunda, model konuşmanın en başındaki bilgileri "unutmaya" başlar.

7. Multi-Modality (Çoklu Form)

Geleneksel dil modelleri sadece metinlerle çalışırken, modern modeller artık **Çoklu Form** yeteneđine sahiptir. Yani aynı model; bir görseli inceleyebilir, bir ses kaydını dinleyebilir veya bir videoyu analiz ederek metin bazlı yanıtlar üretebilir. Bu yetenek, yapay zekayı sadece bir "sohbet botu" olmaktan çıkarıp, dünyayı algılayan bir asistana dönüştürür.

8. Hallucination (Halüsinasyon)

Yapay zekanın en büyük cilvesi halüsinasyonlardır. Model, elindeki verilere dayanarak istatistiksel olarak çok mantıklı görünen ama gerçekte tamamen yanlış olan bilgileri sanki gerçekmiş gibi sunabilir. Bu bir hata deđil, modelin "sonraki kelimeyi tahmin etme" mekanizmasının bir yan ürünüdür. Geliştiriciler olarak görevimiz, çeşitli tekniklerle bu halüsinasyonları en aza indirmektir.