

Bellek Geniřletme (RAG) Konsepti ve İřleyiři

Üretken yapay zeka ekosisteminin en kritik uğrař alanlarından biri olan bu yöntem, büyük dil modellerinin (LLM) statik bilgi sınırlarını aşmasını sağlayan bir "bellek geniřletme" stratejisidir.

1. İsimlendirme: Neden "Bellek Geniřletme"?

Orijinal terim olan **Retrieval Augmented Generation (RAG)**, teknik olarak "Bilgiyi Bulup Getirme ile Artırılmış Üretim" anlamına gelir. Ancak bu kavramın Türkçeleřtirilme sürecinde karşılaşılan bazı alternatifler (Örn: "alma ile artırılmış üretim") işlevsel bağlamı tam olarak yansıtmamaktadır.



Bu eğitim kapsamında tercih ettiğimiz **Bellek Geniřletme** terimi, řu üç nedenden dolayı en uygun karşılık olarak kabul edilmiştir:

- **İřlevsellik:** Yapılan işlemin (modele yeni bilgiler ekleme) semantik karşılığını tam olarak verir.
- **Yalınlık:** Teknik olmayan kullanıcılar için bile anlaşılır bir zemin sunar.
- **Bağlam Uyumu:** Büyük dil modellerinin "neyi bildiğı" ile ilgili süreci doğrudan tanımlar.

2. RAG Etkisi: Bilgi Odaklamanın Gücü

Büyük dil modelleri, internetin büyük bir kısmını kapsayan devasa veri setleriyle eğitilirler. Ancak bu "kocaman veri yığını", her zaman en güncel veya size özel spesifik bilgileri içermez.

RAG Etkisi

LLM | Dil Modeli



BELLEK GENİŞLETME



Bellek genişletme (RAG) yaklaşımı şu temel etkiyi yaratır:

- **Dikkat Odaklama:** Modelin trilyonlarca tokendan oluşan genel eğitim verisindeki "dikkatini" (Attention), bizim sunduğumuz spesifik bir veri kümesine (PDF, video transkripti vb.) yönlendirir.
- **Bilgi Ekleme:** Modelin orijinal eğitim setinde (sarı küre metaforu) yer almayan veriler, sisteme eklenilerek modelin o anki belleği genişletilir.

3. İşlevsel Akış: Eğitim Verisinden Özel Veriye

Teknik olarak bu süreç, modelin önceden öğrendiği genel bilgilerle olan bağı koparmadan, yeni ve spesifik kaynaklardan beslenmesini maksimize etme işlemidir.

RAG Etkisi

LLM | Dil Modeli



- **Girdi:** Bir PDF dosyası veya bir web adresi gibi dış kaynaklar.
- **İşlem:** Modelin genel eğitim setinden beslenme durumunun minimize edilip, sağlanan özel veri kümesinden beslenme durumunun maksimize edilmesi.
- **Sonuç:** Modelin kendi mimarisinden kaynaklanan bilgi kısıtlarını aşarak, tamamen sizin sunduğunuz verilere dayalı ve isabetli yanıtlar üretmesi.