


Üretken yapay zeka eğitimimizin 6. modülünü, bellek genişletme (RAG) süreçlerini profesyonel bir seviyeye taşıyan **İleri Düzey RAG Senaryoları** ile tamamlıyoruz. Genel mimari (Basic RAG), jenerik modellere göre büyük avantaj sağlasa da, gerçek hayattaki karmaşık problemleri çözmek için çoğu zaman özgün müdahaleler ve optimizasyonlar gerektirir.

İleri düzey RAG, genel mimariyi spesifik bir kullanım durumuna, veri yapısına veya amaca göre rafine etme sanatıdır. İşte bu karmaşık dünyayı anlamlı bir haritaya oturtan 12 temel teknik ve strateji:

1. İleri Düzey RAG Kategorizasyonu

İleri düzey teknikleri, bilginin bulunması (retrieval) işlemini referans olarak üç ana kategoride toplayabiliriz:



- Pre-Retrieval (Bulma Öncesi):** Sorgu ve kesit optimizasyonuna odaklanır.
- Retrieval (Bulma):** Vektörlerin kalitesi ve karşılaştırma algoritmalarının optimizasyonunu kapsar.
- Post-Retrieval (Bulma Sonrası):** Bilgi bulunduktan sonra üretim aşamasına geçmeden önceki son rafine işlemlerdir.

2. Pre-Retrieval: Sorgu ve Kesit Optimizasyonu

Bilgiyi aramaya başlamadan önce hem kullanıcının sorusunu hem de verinin parçalanma şeklini iyileştiriyoruz:

- **HyDE (Hypothetical Document Embeddings):** Sorunun kendisine benzeyen vektörleri değil, soruyu yapay zekaya cevaplatıp bu **kurgusal yanıt**a benzeyen vektörleri arama yöntemidir.
 - **Multi-Query:** Kullanıcının sorusunu farklı varyantlarla (soru çoklama) yeniden sorarak daha geniş ve isabetli bir döküman havuzu oluşturur.
 - **Self-Query:** Sorgu içinden önemli anahtar kelimeleri (entitiler) çıkarıp vektör veri tabanında filtreleme yaparak sonuçları daraltır.
 - **Parent Document Retrieval:** Veriyi hem büyük (parent) hem küçük (child) parçalar halinde indeksler. Küçük parçalarda arama yapar ancak bağlamı korumak için büyük parçayı dil modeline gönderir.
 - **Sentence Window Retrieval:** Metni cümle bazlı böler; aranan cümle bulunduğu etrafındaki komşu cümleleri de bağlama dahil eder.
 - **Semantic Chunker:** Metni karakter sayısına göre değil, anlam bütünlüğüne göre bölen akıllı algoritmalar kullanır.
-

3. Retrieval: Vektör ve Kıyas Optimizasyonu

Arama anındaki matematiksel ve anlamsal isabetliliği artırıyoruz:

- **Fine-tuning Embeddings:** Embedding modelini spesifik bir alanın (akademik, Türkçe dil yapısı vb.) terminolojisine göre yeniden eğitmek/ayarlamaktır.
 - **Late Interaction (ColBERT):** Vektörleri tek bir "yoğun" (dense) vektöre indirgemek yerine, anlamsal nüansları koruyan "seyrek" (sparse) vektör temsilleriyle daha hassas karşılaştırma yapar.
 - **MMR (Maximal Marginal Relevance):** Hem benzerliğe hem de sonuç kümesindeki bilgi çeşitliliğine (varyans) odaklanan dengeli bir arama algoritmasıdır.
 - **Hybrid Search:** Semantik (vektör) arama ile klasik karakter bazlı (lexical) aramayı birleştirerek en optimal sonuç kümesini hedefler.
-

4. Post-Retrieval: Üretim Optimizasyonu

Bilgi bulunduktan sonra dil modeline en rafine haliyle sunulması sürecidir:

- **Contextual Compression:** Bulunan dökümanlar içindeki alakasız kısımları bir dil modeli yardımıyla kırpılarak sadece kritik bilgiyi (daha az tokenla) asıl modele gönderir.

- **Re-ranking (Yeniden Sıralama):** Bulunan sonuçları, **Cohere** gibi çok hızlı ve isabetli çalışan özel servislerle en ilgili olandan en alakasız doğru yeniden dizer. Bu, yanlış veya zayıf eşleşen dökümanları elemek için en etkili yöntemlerden biridir.

İLERİ DÜZEY RAG				BAŞLICA YÖNTEM VE STRATEJİLER	
MMR				MULTI-QUERY	
RERANKING				HyDE	
HYBRID SEARCH				SELF-QUERY	
SEMANTIC CHUNKER				CONTEXTUAL COMPRESSION	
				PARENT DOCUMENT RETRIEVAL	
				SENTENCE WINDOW RETRIEVAL	
				FINE-TUNING EMBEDDINGS	
				LATE INTERACTION (ColBERT)	

Sonuç ve Muhakeme

İleri düzey RAG dünyası, literatür ve GitHub üzerinde her geçen gün genişlemektedir. Modellerin bağlam pencereleri (Context Window) 1 milyon tokena kadar genişlese bile, RAG mimarisi hız, maliyet ve isabetlilik avantajı nedeniyle ekosistemin merkezinde kalmaya devam edecektir. Geliştirici olarak göreviniz, bu 12 yöntem arasından projenizin tıkanıdığı noktada hangi inisiyatifi almanız gerektiğini belirleyecek muhakeme yeteneğini geliştirmektir.