


Üretken Yapay Zekâyla Uygulama Geliştirme Eğitimimizin 8. modülüne devam ediyoruz. Bu bölümde, bir dil modelinin "karakterini" ve "işletim verimliliğini" belirleyen üç temel ince ayar (fine-tuning) tekniğini ve bu süreçlerde karşımıza çıkan kritik kavramları inceleyeceğiz.

1. Instruction Fine-Tuning (Talimat Bazlı İnce Ayar)

"Canavarı evilleştirmek" metaforuyla hatırlayacağımız bu süreç, modelin ham yeteneklerini (sonraki kelimeyi tahmin etme) insanlarla anlamlı diyaloglar kurabilecek bir forma dönüştürür.




- **Amacı:** Modelin kendisine verilen talimatları anlamasını ve bunlarla uyumlu yanıtlar üretmesini sağlamaktır.
- **Veri İhtiyacı:** İnsanlar tarafından titizlikle etiketlenmiş, güvenilirliği ve çeşitliliği yüksek veri setleri gerektirir. Bu durum, yöntemin en maliyetli ve zahmetli kısmıdır.
- **Kazanımlar:** * Kullanıcıya yüksek kaliteli ve amaca yönelik etkileşim sunar.
 - Sohbet ilerledikçe modelin daha isabetli yanıtlar vermesini (iteratif öğrenme) sağlar.

2. Knowledge Distillation (Bilgi Damıtma)

Daha hafif, küçük ve hızlı modeller üretmek amacıyla, büyük bir modelin (Teacher) bilgisinin daha küçük bir modele (Student) aktarılması sürecidir.

DISTILLATION | DAMITMA

DAHA HAFİF / ÇEVİK BİR MODEL İÇİN İNCE AYAR



Küçük Model,
eğitim veri seti yerine
Büyük Model'in
çıktılarını referans alır

Daha hafif ve çevik bir model
üretmenin yanı sıra,

Bir modelin sahip olduğu bilgiyi başka
bir modele transfer etmeyi de sağlar




- **Öğretmen-Öğrenci ilişkisi:** Öğrenci model, doğrudan ham veri setinden öğrenmek yerine, öğretmen modelin belirli girdilere verdiği çıktıları referans alır.
- **Çeviklik:** Bu yöntemle, büyük modelin başarımlarına çok yakın sonuçlar veren ama çok daha az yer kaplayan ve hızlı çalışan varyantlar elde edilir.
- **Tanıtım:** Açık kaynak modellerde gördüğümüz "**distilled**" ifadesi, o modelin bu yöntemle oluşturulmuş çevik bir versiyon olduğunu gösterir.

3. Precision & Quantization (Hassasiyet ve Kuantizasyon)

Sinir ağlarındaki **ağırlıklar (weights)** ve **yanlılıklar (biases)**, yani toplam **parametreler**, modelin başarısını belirler. Ancak bu sayıların bellekte tutulma biçimi bir optimizasyon problemidir.

PRECISION & QUANTIZATION

DAHA HAFİF / ÇEVİK BİR MODEL İÇİN İNCE AYAR



0.434919

Single Precision – 32 Bit

0.435

Half Precision – 16 Bit

7

8 Bit Precision (integer)

GGUF | GPT-Generated Unified Format

- **Hassasiyet (Precision):** Normalde parametreler 32 bitlik ondalıklı sayılar (float) olarak tutulur. Ancak her basamak model başarısına aynı oranda katkı sağlamaz.
- **Kuantizasyon:** Parametre değerlerini 32 bit yerine 16 bit, 8 bit veya 4 bit gibi daha küçük veri yapılarıyla temsil etme işlemidir.
- **Avantajları:**
 - **Depolama Tasarrufu:** 70 milyar parametrelili bir modelin kapladığı alanı dramatik şekilde azaltır.
 - **İşletim (Inference) Hızı:** Daha küçük sayılar işlemci tarafından daha kolay ve hızlı okunduğu için model çok daha seri yanıt verir.
- **Formatlar:** Bu projeksiyonu sağlayan gelişmiş yöntemlerden biri **GGUF** formatıdır.

Özet: İnce Ayar Teknikleri

Uygulama geliştiricisi olarak model seçimi yaparken bu kavramlara aşina olmak, projenizin hız ve isabet dengesini kurmanıza yardımcı olur.

İNCE AYAR TEKNİKLERİ

Instruction Fine-Tuning

Distillation

Quantization

Teknik	Odak Noktası	Ana Fayda
Instruction FT	Diyalog ve Talimat Uyumu	Kaliteli Etkileşim

Teknik	Odak Noktası	Ana Fayda
Distillation	Model Boyutu Küçültme	Çeviklik ve Bilgi Transferi
Quantization	Sayısal Hassasiyeti Düşürme	Hız ve Bellek Verimliliği