

LoRA ve QLoRA: Verimli İnce Ayar Teknikleri

Büyük dil modelleri (LLM) devasa boyutlardadır ve en küçükleri bile genellikle 7 milyar parametre içerir. Bu büyüklük, modelleri eğitmek ve saklamak için ciddi donanım kaynakları gerektirir. **LoRA** ve **QLoRA** teknikleri, bu süreci çok daha verimli ve erişilebilir hale getirmek için geliştirilmiştir.

1. LoRA (Low-Rank Adaptation) Nedir?

LoRA, modelin tüm ağırlıklarını güncellemek yerine, düşük ranklı (dereceli) matrisler kullanarak modelin davranışını belirli bir senaryoya uyarlayan tekniktir.

LoRA: Low Rank Adaptation

NEDİR?

Low Rank Adaptation


Düşük Ranklı Matrisler Kullanarak

Model Davranışını Değiştirme / Uyarlama


- **Esas Boyutlar (Intrinsic Dimensions):** Meta AI araştırmacıları, modeller büyüdükçe yeteneklerinin aslında sahip olduklarından çok daha az boyutta (intrinsic dimension) sergileyebildiklerini keşfettiler. Bu, modelin tüm parçalarının performans açısından kritik olmadığını gösterir.

LoRA: Low Rank Adaptation

INTRINSIC DIMENSIONALITY | ESAS BOYUTLAR




- **Microsoft Hipotezi ve Rank:** Microsoft araştırmacıları, eğer esas boyut gerçek boyuttan küçükse, ağırlık matrislerinin de daha düşük **esas ranklara** sahip olabileceğini öne sürmüştür. Rank, matrisin kompleksitesini temsil eden bir değerdir; bu değer düşürüldüğünde modelle çalışmak kolaylaşır.




2. LoRA Nasıl Çalışır?

Modeldeki her bir nöronun arasındaki bağlantı gücü **Ağırlık Matrislerinde (W)** saklanır.



LoRA sürecinde orijinal model ağırlıkları (W) tamamen dondurulur ve onlara hiç dokunulmaz. Bunun yerine, orijinal matristen çok daha düşük ranklı (R) iki yeni matris (A ve B) üretilir.

LoRA: Low Rank Adaptation



INTRINSIC RANKS | ESAS RANK



Hu et al., 2021

Microsoft

Modellerin esas boyutları varsa, model ağırlıklarına ait matrislerin de daha küçük **esas rankları** vardır!

- **Eğitim:** İnce ayar sırasında model sadece bu küçük A ve B matrislerini eğitir.
- **Birleştirme:** Eğitim tamamlandığında, orijinal W matrisi ile yeni öğrenilen AB matrisi toplanarak uyarlanmış yeni ağırlık matrisi (W') elde edilir.

LoRA: Low Rank Adaptation

VERİMLİ BİÇİMDE İNCE AYAR & ÇOK YÖNLÜLÜK

	Weight Matrice Ağırlık Matrisi		
n_{21}	0.434919	-0.134007	0.256713
n_{22}	0.231751	0.640332	0.019876
n_{23}	0.353618	0.412243	0.370004

$$W = \begin{bmatrix} 0.434919 & -0.134007 & 0.256713 \\ 0.231751 & 0.640332 & 0.019876 \\ 0.353618 & 0.412243 & 0.370004 \end{bmatrix}$$


$$A = \begin{bmatrix} 0.1 & 0.2 \\ 0.3 & 0.4 \\ 0.5 & 0.6 \end{bmatrix} \quad B = \begin{bmatrix} 0.7 & 0.8 & 0.9 \\ 1.0 & 1.1 & 1.2 \end{bmatrix}$$

$$AB = \begin{bmatrix} 0.87 & 0.94 & 1.01 \\ 1.49 & 1.62 & 1.75 \\ 2.11 & 2.26 & 2.39 \end{bmatrix}$$

$$W' = W + AB = \begin{bmatrix} 1.304919 & 0.805993 & 1.266713 \\ 1.721751 & 2.280332 & 1.769876 \\ 2.463618 & 2.672243 & 2.760004 \end{bmatrix}$$

LoRA: Low Rank Adaptation

VERİMLİ BİÇİMDE İNCE AYAR & ÇOK YÖNLÜLÜK



Adapted Weight Matrice | Uyarlanmış Ağırlık Matrisi

n21	1.304919	0.805993	1.266713
n22	1.721751	2.280332	1.769876
n23	2.463618	2.672243	2.760004

$$W' = W + AB = \begin{bmatrix} 1.304919 & 0.805993 & 1.266713 \\ 1.721751 & 2.280332 & 1.769876 \\ 2.463618 & 2.672243 & 2.760004 \end{bmatrix}$$

3. Neden LoRA?

LoRA'nın popüler olmasının üç temel nedeni vardır:

- Depolama Tasarrufu:** Sadece küçük LoRA ağırlıklarını saklamak yeterlidir; ana modeli her senaryo için tekrar kaydetmeye gerek kalmaz.
- Hızlı İşletim (Inference):** LoRA ağırlıkları işletim anında ana ağırlıklarla birleştiği için hız kaybı yaşanmaz.
- Çok Yönlülük:** Ana modeli sabit tutup özetleme veya tercüme gibi farklı görevler için modüler paketler halinde dağıtılabilir.

LoRA: Low Rank Adaptation

NEDİR?

Low Rank Adaptation



Depolama Alanı



İşletim Hızı




Çok Yönlülük



4. QLoRA: Kuantizasyon + LoRA

2023 yılında geliştirilen **QLoRA**, sürece **Kuantizasyon** (Quantization) adımını ekler. Orijinal model ağırlıkları **4-bit** olacak şekilde küçültülür ve ince ayar süreci bu hafifletilmiş model üzerinde yapılır.



- **Verimlilik:** LoRA sadece saklama ve işletimde avantaj sağlarken, QLoRA **eğitim sürecini** de hızlandırır ve daha az donanım kaynağı (RAM/GPU) gerektirir. Bu sayede bireysel geliştiriciler bile dev modelleri eğitebilir.



Sonuç

LoRA ve QLoRA, büyük modellerin zekasını koruyarak onları düşük kaynaklarla özelleştirmenin en profesyonel yoludur. Bu teknikler sayesinde, modeller hem modüler kalır hem de işletim maliyetleri minimize edilir.