

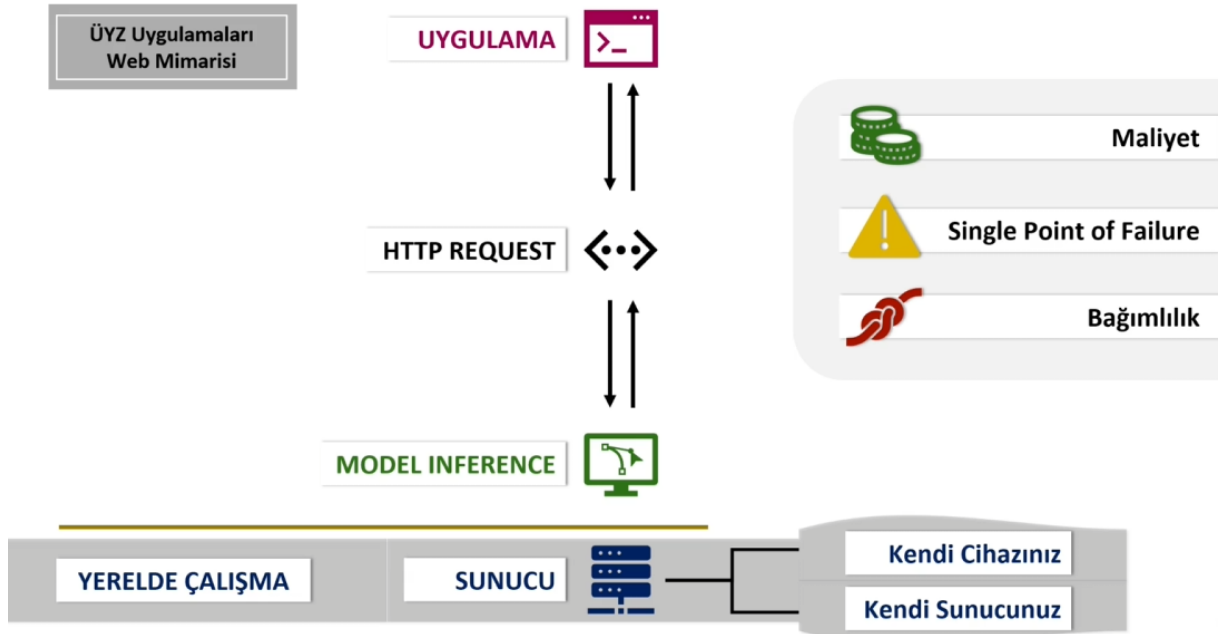
Üretken Yapay Zeka ile Uygulama Geliştirme Eğitimimizin 10. modülünde, dil modellerinin harici bir servis sağlayıcıya bağımlı kalmadan **yerelde (local)** nasıl işletilebileceğini ve bu amaçla kullanabileceğimiz **açık kaynaklı (open-source)** model ekosistemini inceliyoruz.

Şimdiye kadar geliştirdiğimiz uygulamalar genellikle bir bulut sunucusu üzerinden (OpenAI, Google, Anthropic vb.) API çağrıları ile çalışmaktaydı. Ancak bu klasik mimari, gerçekçi iş modellerinde yönetilmesi gereken bazı riskler barındırır.

1. Neden Yerelde Çalışma? Web Mimarisinin Riskleri

Klasik web mimarisinde işletim (inference) süreci harici bir servis sağlayıcı tarafından halledilir. Bu durum üç temel problem alanı yaratır:

- **Maliyet:** Servis sağlayıcı ücretlerinin uzun vadeli planlanması zorunluluğu.
- **Single Point of Failure (Tekil Hata Noktası):** Servis sağlayıcıda yaşanacak bir kesintinin tüm sisteminizi çalışamaz hale getirmesi.
- **Bağımlılık ve Değişkenlik:** Modellerin sürekli modifiye edilmesi (güvenlik önlemleri, RLHF vb.) nedeniyle model davranışının zamanla öngörülemez şekilde değişmesi.




Yerel çalışma; maliyeti öngörülebilir kılar, yedekleme imkanı sunarak riskleri minimize eder ve en önemlisi **model davranışının sabit kalmasını** garanti altına alır.

2. Yerel İşletim Gereksinimleri: İşletim ve Depolama

Yerelde çalışma büyük kazanımlar sağlasa da, beraberinde iki kritik teknik sorumluluk ve "bedel" getirir:

Yerel İşletim Uygulamaları



1. **Inference (İşletim):** Milyarlarca parametrenin hesaplanması için ciddi bir işlemci gücü (CPU/GPU) ve yüksek miktarda RAM bellek gereklidir. Üretim düzeyinde sistemlerde LoRA, kuantizasyon ve distilasyon gibi optimizasyon tekniklerine hakimiyet önem kazanır.
2. **Storage (Depolama):** Büyük modellerin disk üzerinde genellikle 50 GB ile 100 GB arasında değişen devasa alanlara ihtiyaç duymasındır.

3. Kullanılacak Yazılımlar: LM Studio ve Ollama

Büyük dil modellerini yerel cihazlarda kolayca çalıştırabilmek için iki popüler ve ücretsiz alternatif öne çıkmaktadır:

Yerel İşletim Uygulamaları

KULLANILACAK YAZILIMLAR

YEREL İŞLETİM YAZILIMLARI



LM Studio




ollama

- **LM Studio (Language Model Studio):** Kullanımı son derece basit olan bu platform, farklı modelleri keşfetmek ve test etmek için idealdir.
- **Ollama:** İsmi Llama modellerinden alan ve özellikle terminal üzerinden hızlı yönetim sağlayan güçlü bir araçtır.

4. Açık Kaynak Model Ekosistemi

Günümüzde değer üretme potansiyeli yüksek modeller şu üç grupta kategorize edilebilir:



- **Başlıca Aileler:** Meta'nın **Llama 2** (yakında Llama 3), Mistral AI'nın **Mixtral** ve Cohere'in **Command R** modelleridir. Özellikle 7 milyar parametrelilik **Mistral** modeli, küçük ölçekli olmasına rağmen yüksek başarımıyla dikkat çekmektedir.
- **Yeni ve Umud Vadedenler:** Performans ve mimari açısından fark yaratan **DBRX** ve **Jamba** modelleri.
- **Deneyisel Çalışmalar:** **Stable LM**, **Phi 2** ve **Gemma** gibi modeller; ince ayar ve model üretimi süreçlerini öğrenmek için oldukça faydalıdır.