

BAŞLIK: NATURAL LANGUAGE PROCESSING (NLP): GENEL TEKRAR SORULARI

TÜR: Çoktan Seçmeli Değerlendirme (Sorular 19.1 - 19.3 konularını kapsar)

SORULARIN CEVAPLARI EN ALTTA BULUNMAKTADIR.

1. NLP'de 'Corpus' (Derlem) terimi neyi ifade eder?

- A) Bir cümledeki noktalama işaretini.
- B) Bir modelin doğruluk oranını.
- C) Analiz için kullanılan metin koleksiyonunu.
- D) Tek bir kelimeyi.

2. Case Folding (küçük harfe çevirme) işleminin temel amacı nedir?

- A) "Python" ve "python" gibi aynı kelimenin farklı yazımlarını birleştirip vocabulary boyutunu küçültmek.
- B) Cümleleri birleştirmek.
- C) Sayıları harflere çevirmek.
- D) Metni tamamen silmek.

3. Stopwords (durma kelimeleri) nelerdir ve neden silinir?

- A) Cümledeki en önemli anahtar kelimelerdir, asla silinmez.
- B) "the", "is", "at" gibi çok sık geçen ama anlam taşımayan kelimelerdir; veri boyutunu azaltıp analizi iyileştirmek için silinirler.
- C) Sadece büyük harfli kelimelerdir.
- D) Sadece sayılardır.

4. Lemmatization ile Stemming arasındaki fark nedir?

- A) Stemming her zaman daha doğrudur.
- B) Lemmatization sadece sayılarla çalışır.
- C) İkisi birebir aynı sonucu üretir.
- D) Lemmatization sözlük tabanlı, dilbilgisi kurallarına uygun doğru kökü bulur (örn. studies->study); Stemming ise basit kural tabanlıdır ve hatalı sonuçlar üretebilir (örn. studies->studi).

5. VADER (Valence Aware Dictionary for Sentiment Reasoning) neyi ölçer ve hangi tür metinler için özellikle optimize edilmiştir?

- A) Sadece dilbilgisi hatalarını; resmi belgeler için.
- B) Sadece kelime sayısını sınırlamak için.
- C) Metnin duygu yoğunluğunu (-1 ile +1 arası compound skoru); sosyal medya metinleri için (emoji, büyük harf, noktalama işaretlerini dikkate alır).
- D) Sadece kelime sayısını; akademik makaleler için.

6. TF-IDF, basit Count Vectors (Bag of Words) yöntemine göre ne sağlar?

- A) Sadece kelime sayısını sayar, hiçbir ek bilgi vermez.
- B) Kelimeleri tamamen siler.
- C) Sadece görsel bir çıktı üretir.
- D) Yaygın kelimelerin (örn. "the") etkisini azaltıp, nadir ve ayırt edici kelimelere daha yüksek ağırlık verir.

7. N-gram kavramı ne anlama gelir? (Örn. Bigram)

- A) Ardışık N kelimenin kombinasyonunu (bigram = 2 ardışık kelime).
- B) Tek tek kelimeleri.
- C) Sadece sayısal değerleri.
- D) Cümledeki toplam kelime sayısını.

8. Metin sınıflandırmada Logistic Regression'ın yüksek boyutlu (TF-IDF gibi) verilerle iyi çalışmasının nedeni nedir?

- A) Hiçbir zaman yüksek boyutlu veriyle çalışamaz.
- B) Sadece küçük veri setlerinde çalışabildiği için.
- C) Sadece görüntü verisiyle çalıştığı için.
- D) Doğrusal ve hesaplama açısından verimli bir model olması, yüksek boyutlu seyrek (sparse) matrislerle etkin çalışabilmesi.

9. Kozmos Amazon Sentiment Analysis projesinin temel iş problemi nedir?

- A) Amazon ürün yorumlarını duygu analiziyle pozitif/negatif olarak sınıflandırmak.
- B) Ürün fiyatlarını tahmin etmek.
- C) Stok yönetimi yapmak.
- D) Web sitesi trafiğini analiz etmek.

10. Bu projede VADER ile üretilen 'compound' skoru, sentiment_label (pos/neg) etiketine nasıl dönüştürülür?

- A) Sadece yorumun uzunluğuna bakılarak.
- B) Kullanıcının puanına hiç bakılmadan otomatik olarak.
- C) compound > 0 ise "pos", aksi halde "neg" gibi bir eşik kuralıyla.
- D) Rastgele atama ile.

11. Projede TF-IDF vektörleriyle eğitilen Logistic Regression modelinin performansı hangi yöntemle değerlendirilir?

- A) Sadece görsel inceleme ile.
- B) Sadece eğitim setinde tek seferlik doğruluk ölçümüyle.
- C) Hiçbir değerlendirme yapılmaz.
- D) Cross-validation (çapraz doğrulama, örn. 5-fold) ile.

12. Modelin yeni, daha önce görülmemiş bir yorumu sınıflandırabilmesi için o yorum ne yapılmalıdır?

- A) Yorum hiçbir işlemten geçmeden tahmin edilir.
- B) Doğrudan modele metin olarak verilir.

- C) Eğitimde kullanılan vectorizer (TF-IDF/Count) ile aynı vocabulary kullanılarak sayısal vektöre dönüştürülmelidir.
- D) Yorum rastgele bir sayıya eşlenir.

13. Random Forest ile Logistic Regression'ı bu tür bir metin sınıflandırma projesinde karşılaştırırken hangi metrik kullanılır?

- A) Sadece eğitim süresi.
- B) Cross-validation ile elde edilen ortalama accuracy (doğruluk) skoru.
- C) Sadece dosya boyutu.
- D) Sadece kullanılan RAM miktarı.

14. Wikipedia metin ön işleme projesinde amaç nedir?

- A) Wikipedia metinlerini temizleyip (ön işleyip) frekans analizi ve görselleştirme yapmak.
- B) Wikipedia'yı çevirmek.
- C) Yeni Wikipedia makaleleri yazmak.
- D) Wikipedia sunucularını yönetmek.

15. Projede 'tek fonksiyonda tüm işlemleri birleştiren modüler yapı' kurmanın avantajı nedir?

- A) Hiçbir avantajı yoktur.
- B) Tüm ön işleme adımlarını (lowercase, noktalama, sayı, stopwords temizliği vb.) tek bir çağrıyla tekrar tekrar, tutarlı şekilde uygulayabilmek.
- C) Kodu daha karmaşık hale getirmek.
- D) Sadece kod satırı sayısını artırmak.

16. Terim frekansı (term frequency) hesaplandıktan sonra barplot ile görselleştirmenin amacı nedir?

- A) Sadece estetik amaçlıdır.
- B) Metinde en sık geçen kelimeleri görsel olarak hızlıca tespit edebilmek.
- C) Kelimeleri silmek için.
- D) Veriyi şifrelemek için.

17. Wordcloud (kelime bulutu) görselleştirmesinde kelime boyutu neyi temsil eder?

- A) Kelimenin metindeki geçme sıklığını (sık geçen kelimeler daha büyük görünür).
- B) Kelimenin rastgele bir özelliğini.
- C) Kelimenin harf sayısını.
- D) Kelimenin alfabetik sırasını.

CEVAP ANAHTARI

1-C 2-A 3-B 4-D 5-C 6-D 7-A 8-D 9-A 10-C 11-D 12-C 13-B 14-A 15-B 16-B 17-A