

Yapay zeka ekosisteminde řu an tam bir "modeller savařı" yařanıyord. Eđitimin bu ařamasına kadar tokenları, parametreleri ve bađlam penceresini öđrendik; ancak asıl soru řu: **Geliřtirdiđimiz uygulama için hangi modeli seřmeliyiz?** Bugün piyasada yüzden fazla model ve bunların binlerce varyantı bulunuyor. Bir uygulama geliřtiricisi olarak bu kalabalıđın içinde kaybolmamak için, modelleri birbiriyle kıyaslamayı sađlayan temel kriterleri ve ana oyuncularını tanımamız gerekiyor.

Devlerin Yarıřı: Dil Modellerini Birbiriyle Nasıl Kıyaslarız?

Dil modellerini kıyaslarken dünyayı iki ana kampa ayırıyoruz: **Ticari Modeller** ve **Açık Kaynak Modeller**.

- **Ticari Modeller (SaaS):** GPT-4, Claude ve Palm 2 gibi modeller bu grubun liderleri. Bunlar dev řirketler tarafından kapalı devre olarak geliřtirilir. İç yapılarını (parametre sayılarını, eğitim verilerini) tam olarak bilemeyiz ama sundukları performans genellikle "altın standart" kabul edilir.
- **Açık Kaynak Modeller:** Meta'nın **Llama-2** serisiyle bařı çektiđi bu grup, řeffaflıđı temsil eder. Bu modellerin "ađırlıklarını" indirip kendi sunucunuza kurabilir ve üzerinde dilediđiniz gibi modifikasyon yapabilirsiniz. Tıpkı Linux'un farklı sürümleri olduđu gibi, açık kaynak modellerin de her hafta yeni bir "ince ayar" (fine-tuned) versiyonuyla karřılařmak mümkün.

1. Kıyaslama Kriterleri: Parametre ve Hafıza

Bir modeli diđerleriyle yan yana koyduđumuzda baktıđımız iki ana rakam vardır:

Parametre Sayısı (Zeka Kapasitesi)

Parametreler modellerin karmařıklıđını temsil eder.

- **Palm 2:** 340 Milyar parametre ile devasa bir yapı sunar.
- **GPT-3.5 Turbo:** 175 Milyar parametre ile dengeli bir performans sergiler.
- **GPT-4 Turbo:** Burada ilginç bir durum var. OpenAI artık teknik detayları paylařma konusunda daha ketum davranıyor. Ancak sektördeki yaygın kanaat, GPT-4'ün **1.8 Trilyon** parametre gibi akıl almaz bir ölçekte olduđu yönünde.

Bađlam Penceresi (Hafıza Kapasitesi)

Uygulamamıza ne kadar büyük bir veri yükleyebileceđinizi bu pencere belirler.

- **GPT-4 Turbo:** 128.000 token ile koca bir kitabı tek seferde "okuyup" analiz edebilir.

- **Claude 2.1:** 200.000 token'a çıkan penceresiyle şu an bu yarışın bellek şampiyonu gibi görünüyor.

2. Fark Yaratan Oyuncular: Grok ve Diğerleri

Bazı modeller, eğitildikleri veri setleriyle diğerlerinden ayrışır. Örneğin Elon Musk'ın ekibi tarafından geliştirilen **Grok**, sadece Twitter (X) üzerindeki canlı veri akışıyla eğitildiği için güncel olaylara tepki verme konusunda diğer modellerden çok daha farklı bir karakter sergiliyor. Inflection, Command ve Jurassic gibi modeller ise daha kısıtlı bütçelerle çok daha "efektif" ve odaklanmış çözümler sunmaya çalışarak rekabeti kızıştırıyor.

3. Doğru Modeli Nasıl Seçeceğiz? (Benchmarklar)

"En iyi model hangisi?" sorusunun cevabı her gün değişebiliyor. Bu yüzden dünyaca kabul görmüş iki büyük referans noktasına güveniyoruz:

1. **Stanford HELM (Holistic Evaluation of Language Models):** Stanford Üniversitesi tarafından yürütülen bu proje, modelleri sadece metin üretme değil; aritmetik beceri, okuduğunu anlama ve muhakeme gibi 10'dan fazla farklı değişkene göre sorguluyor.
2. **Hugging Face Open LLM Leaderboard:** Özellikle açık kaynak dünyasını takip etmek istiyorsanız burası en doğru adres. Neredeyse her gün eklenen yeni modellerin birbiriyle nasıl yarıştığını şeffaf bir tabloda görebiliyorsunuz.

Sonuç

Uygulama geliştirme aşamasında tek bir "en iyi" model yoktur. Projenizin ihtiyacına göre; bazen Claude'un devasa hafızasına, bazen GPT-4'ün üstün muhakemesine, bazen de Llama-2'nin sağladığı gizlilik ve özelleştirme imkanına ihtiyaç duyacaksınız. Bu tabloyu ve benchmarkları takip etmek, projeniz için en doğru "motoru" seçmenizi sağlayacaktır.