

Yapay zeka modellerinin performansını ölçmek ve birbirleriyle kıyaslamak, dışarıdan bakıldığında oldukça subjektif görünebilir. "Hangi model daha iyi?" sorusu, cevabı kişiden kişiye değişen bir tercih meselesi gibi dursa da, aslında bu işin arkasında oldukça somut ve bilimsel bir çerçeve yatıyor.

2020 yılında OpenAI ekibinin başlattığı ve 2022'de DeepMind'ın yeni bir boyut kazandırdığı **Ölçekleme İlkeleri (Scaling Laws)**, bugün uygulama geliştiricilerin hangi modeli neden seçmesi gerektiğini anlamasını sağlayan en temel rehberdir. Gelin, bu performans denklemindeki üç ana aktörü ve canavarımızı ehlileştirirken hangi "ayarlarla" oynamamız gerektiğini birlikte inceleyelim.

Yapay Zekada Performansın Üç Silahşörü: Ölçekleme İlkeleri

Bir dil modelinin ne kadar "akıllı" olacağını belirleyen üç temel değişken vardır. Bunları zihninizde sağa ve sola kaydırılabilen üç ayrı ayar sürgüsü (slider) gibi hayal edebilirsiniz:

- Model Büyüklüğü (Parametre Sayısı - Yeşil Sürgü):** Sinir ağının ne kadar karmaşık ve derin olduğunu temsil eder.
- Eğitim Verisinin Büyüklüğü (Token Sayısı - Mavi Sürgü):** Modelin eğitilirken ne kadar çok veri "okuduğunu" temsil eder.
- İşlem Gücü (Petaflop/s-days - Kırmızı Sürgü):** Bu eğitimi gerçekleştirmek için harcanan donanım ve zaman maliyetidir.

1. OpenAI ve "Daha Büyük, Daha İyidir" Dönemi (2020)

OpenAI'nın 2020 yılındaki meşhur çalışması, bu üç sürgünün de performansı doğrudan artırdığını kanıtladı. Ancak her kaynağımız sonsuz olmadığı için bir önceliklendirme yapmamız gerekiyordu. O dönemki bulgulara göre öncelik sırası şöyleydi:

- Birinci Öncelik:** Parametre sayısını (modeli) büyütmek.
- İkinci Öncelik:** Veri miktarını (tokenları) artırmak.
- Üçüncü Öncelik:** Daha fazla işlem gücü kullanmak.

Kısacası; "Modeli ne kadar büyütürsen, o kadar akıllı olur" anlayışı bu dönemde genel kabul gördü.

2. DeepMind ve Chinchilla Devrimi (2022)

Ancak 2022 yılında Google DeepMind ekibi, **Chinchilla** isimli modellerini eğitmeden önce farklı bir hipotezi test etti: "Ya modelleri sadece büyütmek yerine, daha küçük modelleri çok daha fazla veriyle daha uzun süre eğitirsek?"

Sonuçlar yapay zeka dünyasında kartların yeniden dağıtılmasına neden oldu. DeepMind şunu gösterdi: Toplam bütçeyi (maliyet ve işlem gücü) değiştirmeden, **modeli biraz küçültüp (Parametre sürgüsü sola), eğitim süresini ve veriyi artırırsanız (Veri sürgüsü sağa)**, devasa ama az eğitilmiş modellerden çok daha iyi performans alabiliyorsunuz.

Geliştiriciler İçin Bu Ne Anlama Geliyor?

Uygulamanız için bir model seçerken veya performansından memnun kalmadığınızda şu iki çıkarım size yol gösterecektir:

- **Verimlilik vs. Güç:** Her zaman en yüksek parametrelili (örneğin 1.8 trilyon parametrelili olduğu düşünülen GPT-4 gibi) modele ihtiyacınız olmayabilir. Doğru veriyle ve daha uzun süre eğitilmiş (Chinchilla optimizasyonu yapılmış) daha küçük bir model, hem daha hızlı çalışacak hem de maliyetlerinizi düşürecektir.
- **Sınırlı Kaynak Yönetimi:** Eğer kendi modelinizi eğitecekseniz veya ince ayar (fine-tuning) yapacaksanız, tüm bütçeyi devasa bir model kurmaya harcamak yerine; verinizi temizlemeye, çeşitlendirmeye ve modelinizi bu veriyle daha fazla tur döndürmeye odaklanmak çok daha isabetli bir karardır.

Sonuç

Yapay zekada performans rastlantısal değildir. Model büyüklüğü, veri miktarı ve işlem gücü arasındaki o hassas dengeyi kurabilmek, kaliteli bir uygulamanın temelidir. Bugün Meta'nın Llama serisi gibi modellerin bu kadar başarılı olmasının sırrı, tam da bu "daha küçük modeli daha çok veriyle eğitme" (Chinchilla) prensibine dayanmalarından geliyor.