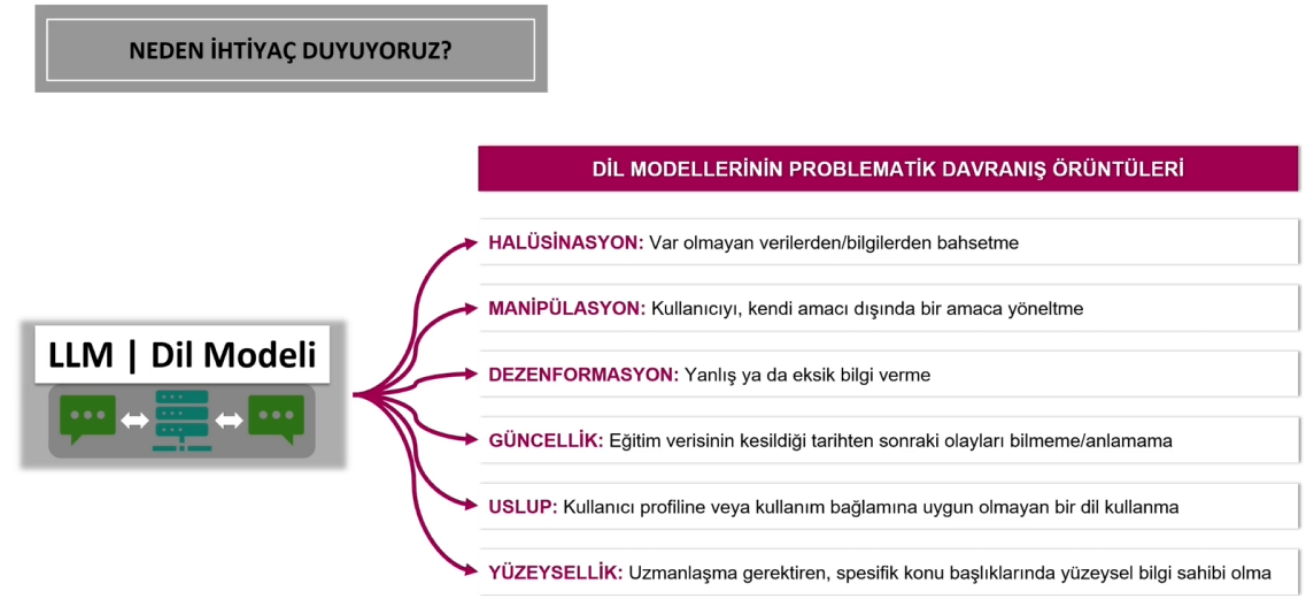


Üretken Yapay Zekâ ile Uygulama Geliştirme Eğitimimizin 6. Modülüne hoş geldiniz. Bu bölüm, ekosistemin değer üretim zincirindeki en kritik duraklarından biri olan **Bellek Genişletme (Retrieval Augmented Generation - RAG)** konusuna odaklanmaktadır. Profesyonel düzeyde uygulamalar geliştirebilmek için RAG stratejilerini tüm yönleriyle, avantajları ve kısıtlarıyla kavramak büyük önem taşımaktadır.

1. Neden RAG? Dil Modellerinin Sınırları

Büyük dil modelleri (LLM) büyüleyici yetenekler sunsa da, mimari yapılarından kaynaklanan ve kullanıcı deneyimini doğrudan etkileyen bazı kronik problemlere sahiptir. Bu sınırlılıkları anlamak, RAG konseptine neden bu kadar büyük yatırım yapıldığını açıklar.




Dil modellerinin temel problematik davranış örüntüleri şunlardır:

- **Halüsinasyon:** Modelin, var olmayan bilgileri gerçekmiş gibi bir özgüvenle sunmasıdır; bu, Transformer mimarisinin istatistiksel doğasının bir sonucudur.
- **Manipülasyon:** Kullanıcıyı kendi niyeti dışında belirli bir kanaate veya etik olmayan yönler çekme riskidir.
- **Dezenformasyon:** Bilgi eksikliği veya yanlış veri eşleşmesi nedeniyle hatalı çıktılar üretilmesidir.
- **Güncellik (Knowledge Cutoff):** Modellerin eğitim verisinin kesildiği tarihten sonraki olaylar hakkında bilgisiz kalmasıdır.

- **Üslup:** Belirli dillerde (Örn: Türkçe) veya niş formatlarda temsil oranının düşük olması sebebiyle beklenen performansın sergilenememesidir.
- **Yüzeysellik:** Spesifik uzmanlık gerektiren konularda modelin kendini tekrar eden veya sıkı yanıtlar vermesidir.

2. Model Davranışlarını Biçimlendirme Piramidi


Modelin davranışını değiştirmek veya bilgi dağarcığını geliştirmek için kullanılan yöntemler bir optimizasyon piramidi şeklinde ele alınabilir. Piramitte yukarı çıkıldıkça uygulama kolaylığı artar, ancak kalıcı etki azalır.



- **Model Eğitimi & İnce Ayar (Fine-Tuning):** Teknik uzmanlık ve yüksek kaynak gerektiren, daha çok modelin "nasıl hareket etmesi" gerektiğini (üslup, yaklaşım) belirleyen yöntemlerdir.
- **Bellek Genişletme (RAG):** Piramidin tam ortasında yer alan en optimal çözümdür. Harcanan emek ile elde edilen kazanç son derece uyumludur ve özellikle "modelin ne bilmesi gerektiği" sorunu için en iyi yöntemdir.
- **Girdi Mühendisliği (Prompt Engineering):** Zero-shot, Few-shot ve sohbet etkileşimlerini kapsayan, uygulanması en kolay ancak bağlam penceresiyle sınırlı olan yöntemlerdir.

3. Optimizasyon Düzlemi: Bağlam vs. Model

LLM davranışlarını optimize ederken iki temel soruya yanıt ararız: "**Model ne bilmeli?**" ve "**Model nasıl hareket etmeli?**".



- **Bağlam Optimizasyonu (RAG):** Eğer hedef modelin yeni bilgiler öğrenmesi ve bunlara sadık kalarak yanıt vermesi ise RAG tercih edilmelidir.
- **Model Optimizasyonu (Fine-Tuning):** Eğer hedef modelin üslup, format ve karakteristik yaklaşımını kalıcı olarak değiştirmek ise ince ayar gereklidir.
- **Hibrit Yaklaşım:** Hem bilgi dağarcığını hem de hareket tarzını aynı anda etkilemek istiyorsak, girdi mühendisliği, RAG ve ince ayar yöntemleri birlikte çalıştırılmalıdır.

Modül Yol Haritası

Bu modül kapsamında RAG mimarisini derinlemesine inceleyeceğiz. **Embedding modellerinin** matematiksel temellerinden başlayacak, **vektör veri tabanlarını** ve **semantik arama** operasyonlarını öğrenecek, son olarak **ileri düzey RAG stratejileriyle** profesyonel uygulamalar için gerekli olgunluğa ulaşacağız.