


Bellek genişletme (RAG) süreçlerinde kelimelerin nasıl sayısallaştığını anlamak için en kritik kavramlardan biri olan **Word Embeddings** (Kelime Gömme) konusuna daha yakından bakıyoruz. Önceki bölümlerde "sihirli" birer sayı dizisi gibi görünen bu vektörlerin, aslında dilin anlamsal yapısını ve karakteristik özelliklerini nasıl kodladığını (Feature Vectors) somut bir örnek üzerinden inceleyeceğiz.

1. Koordinat Düzleminde Kavramsal Eşleştirme

Kelimeler arasındaki anlamsal ilişkileri matematiksel bir uzayda temsil etmek için iki boyutlu bir koordinat düzlemi hayal edelim. Bu düzlemde dikey eksen **Sosyal Sınıf** (Soylu-Halk), yatay eksen ise **Cinsiyet** (Erkek-Kadın) özelliklerini gösterebilir.



Bu örnek uzayda dört farklı karakteri kodladığımızda şu koordinatlara (vektörlere) ulaşırız:

- **Kraliçe:** Sosyal Sınıf: 2 (Soylu), Cinsiyet: 2 (Kadın) → **[2, 2]**
- **Terzi Kadın:** Sosyal Sınıf: 1 (Halk), Cinsiyet: 2 (Kadın) → **[1, 2]**
- **Kral:** Sosyal Sınıf: 2 (Soylu), Cinsiyet: 1 (Erkek) → **[2, 1]**
- **Çiftçi Adam:** Sosyal Sınıf: 1 (Halk), Cinsiyet: 1 (Erkek) → **[1, 1]**

Bu basit işlemle, kelimeler arasındaki "uzaklığı" ölçülebilir hale geliriz. Örneğin; Kral ve Kraliçe arasındaki mesafe 1 birimken, hiçbir ortak özelliği olmayan Terzi Kadın ve Kral arasındaki mesafe $\sqrt{2}$ birimdir. Bu, makinelerin kelimeler arasındaki anlamsal benzerliği tespit etmesinin temelidir.

2. Vektör Aritmetiği ve Anlamsal Değişim

Koordinat düzlemindeki bu noktalar sayesinde anlamsal değişimleri vektör işlemleriyle ifade edebiliriz:

- **Sosyal Sınıf Farkı:** Kraliçe vektöründen "soyluluk" özelliğini çıkarırsak geriye Terzi Kadın kalır.
- **Cinsiyet Farkı:** Kral vektöründen "erkek" özelliğini çıkarıp "kadın" özelliğini eklersek Kraliçe kavramına ulaşırız.
- **Çift Karakteristikli Değişim:** Kraliçeyi hem soylu olmaktan çıkarıp hem de erkek karakter olarak pozisyonlandırırırsak kendimizi Çiftçi Adam noktasında buluruz.

3. Gerçekçi Word Embeddings: N-Boyutlu Uzak

Gerçek dünya senaryolarında kelimeler sadece iki nitelik (cinsiyet ve sosyal sınıf) temsil edilmez. Dilin karmaşıklığını yansıtabilmek için yüzlerce, hatta binlerce boyuta (n-boyutlu uzak) ihtiyaç duyulur.

Bellek Genişletme - RAG

WORD EMBEDDINGS			
			
SOSYAL SINIF	2		0.02301454
CİNSİYET	2		0.07399456
BOY	2		0.03350061
KİLO	1		0.03240441
ZEKA	2		0.01559722
KONUŞTUĞU DİL	1		0.06170322
LİDERLİK YETKİNLİĞİ	2		0.04880136
MENSUP OLDUĞU AİLE	1		0.02319903
.	.		.
.	.		.
.	.		.
N No'lu ÖZELLİK	X		X

Gerçekçi bir Word Embeddings uygulamasında şu farklar ortaya çıkar:

- **Nitelik Çeşitliliği:** Boy, kilo, zeka, liderlik yetkinliği, mensup olunan aile gibi sayısız "feature" (özellik) vektöre eklenir.
- **Sürekli Değerler:** Değerler 1 veya 2 gibi kategorik sayılar yerine, çok sayıda ondalık basamağı olan sürekli (continuous) verilerden oluşur (Örn: 0.02301454).

Sonuç

Bu metaforik yaklaşım, embeddinglerin neden "sihir" olmadığını kanıtlar. Makineler, kelimeleri bu devasa nitelik matrisleri içinde konumlandırarak, insanların anlık olarak kurduğu anlamsal bağları istatistiksel ve matematiksel bir kesinlikle taklit ederler.