

Bellek genişletme (RAG) mimarisinin kavramsal ve matematiksel temellerini inceledikten sonra, şimdi bu teorik bilgiyi uygulama dünyasına taşıyoruz. Bu bölümde, sektörde öne çıkan en güçlü **embedding modellerini** teknik özellikleri ve performans dengeleriyle tanıyacağız.

1. Başlıca Embedding Modelleri ve Boyut Farkları

Embedding modelleri arasındaki en belirgin fark, her bir kelimeyi veya döküman kesitini temsil etmek için kullandıkları sayı adedi, yani "boyut" (dimension) sayısıdır.

BAŞLICA EMBEDDING MODELLERİ



Embedding V3 Large	3072
Embedding V3 Small	1536
Ada-002	1536



Embed English V3	1024
Embed Multilingual V3	1024
Embed English Light V3	384
Embed Multilingual Light V3	384



Hugging Face

all-MiniLM-L6-v2	384
------------------	-----

- **OpenAI:** Uzun süre standart kabul edilen **Ada-002** modeli 1536 boyuta sahiptir. Yeni nesil modellerde ise **V3 Small** (1536 boyut) ve çok daha yüksek çözünürlüklü **V3 Large** (3072 boyut) seçenekleri sunulmaktadır.
- **Cohere:** Versiyon 3 serisi ile İngilizce ve çoklu dil (Multilingual) desteği sunan modelleri 1024 boyuta kadar çıkmaktadır. Ayrıca hız odaklı senaryolar için 384 boyutlu "Light" versiyonları da mevcuttur.
- **Hugging Face:** Açık kaynak dünyasının popüler tercihi olan **all-MiniLM-L6-v2**, 384 boyutlu vektörler üretir. Boyut sayısı düşük görünse de, ücretsiz ve erişilebilir olmasıyla yüksek performans sergiler.

2. Boyut Sayısındaki Kritik Denge (Trade-off)

Bir modelin boyut sayısının artması, kavramların vektör uzayına daha yüksek bir çözünürlükle ve daha iyi bir izahla aktarılması anlamına gelir. Ancak bu durum şu maliyetleri de beraberinde getirir:

- **Hesaplama Karmaşıklığı:** 3072 boyutlu iki vektör arasında nokta çarpım (dot product) yapmak, 1536 boyutluya göre çok daha fazla işlem gücü gerektirir.

- **Depolama Alanı:** Milyonlarca vektörün saklandığı bir senaryoda, her bir vektörün boyut sayısı doğrudan veritabanı maliyetini etkiler.

Sonuç: İsbet oranının kritik olduğu yerlerde yüksek boyutlu modelleri; kaynak yönetiminin ve hızın ön planda olduğu senaryolarda ise daha mütevazı boyutlu modelleri tercih etmelisiniz.

3. Gerçekçi Vektörlerin Anatomisi

Gerçek hayattaki embedding vektörleri, metaforik örneklerdeki gibi basit (1, 2 gibi) tam sayılardan değil, son derece hassas ondalıklı sayılardan oluşur.

WORD EMBEDDINGS	KRALİÇE VEKTÖRÜ	GERÇEKÇİ VEKTÖR
SOSYAL SINIF	2	0.02301454
CİNSİYET	2	0.07399456
BOY	2	0.03350061
KİLO	1	0.03240441
ZEKA	2	0.01559722
KONUŞTUĞU DİL	1	0.06170322
LİDERLİK YETKİNLİĞİ	2	0.04880136
MENSUP OLDUĞU AİLE	1	0.02319903
.	.	.
.	.	.
.	.	.
N No'lu ÖZELLİK	X	X

Gerçek bir vektör incelendiğinde şu iki özellik öne çıkar:

1. **Hassas Değerler:** Vektörler, kelimenin anlamsal "karakterini" belirleyen çok basamaklı ondalıklı sayılardan oluşur.
2. **Negatif Değerler:** Vektörlerde eksi değerli sayıların bulunması, o özelliğin n-boyutlu uzaydaki yönünü belirlemek için kullanılır.

Aynı cümle (Örn: "*Mevsimler neden oluşur?*") her üç modelde de test edildiğinde, her modelin kendine has "know-how" (teknik bilgi) birikimi nedeniyle farklı sayılar ve farklı basamak uzunlukları ürettiği görülür.

