

Bellek genişletme (RAG) sürecinin en kritik bileşenlerinden biri olan **Semantik Arama (Semantic Search)**, kullanıcının niyetini ve kelimelerin anlamsal bağlamını matematiksel bir kesinlikle yakalamamızı sağlar. Bu bölümde, klasik arama yöntemlerinden farklarını, kullanılan matematiksel metrikleri ve sonuç setini zenginleştiren algoritmaları inceleyeceğiz.


1. Lexical (Anahtar Kelime) vs. Semantik Arama

Veri parçaları arasında sorgu yaparken iki temel yaklaşım mevcuttur:

- **Lexical / Keyword Search:** Karakter bazlı eşleşmeye odaklanır (Ctrl+F mantığı). "Fare" kelimesini arattığınızda karşınıza hem "bilgisayar faresi" hem de "hayvan olan fare" ile ilgili sonuçlar çıkar; çünkü sistem kelimenin bağlamını değil, harf dizilimini kontrol eder.
- **Semantic Search:** Karakter eşleşmesi olmasa bile konsept bazlı eşleşmeye odaklanır. Örneğin "deney faresi" araması yaptığınızda, içinde "fare" kelimesi geçmeyen "laboratuvar hayvanı" veya "sıçan" gibi terimleri içeren ilgili sonuçları bulabilir.

SEMANTİK ARAMA	
Lexical / Keyword Search	Semantic Search
fare	deney faresi
... fareler metroyu sarmıştı ...	... labirentte peynir arayan hayvanlara yardım et ...
...bebek fareyi gördüğünde...	... deneklerin hepsi aynı peyniri tercih etti ...
... ve farenin kablosu kısaydı ...	... deneyde kullanılan sıçanlar aynı türden ...
...kitabın adı fareli köyün kaval...	... araştırmada on laboratuvar hayvanı kullanıldı ...

Semantik arama, bellek genişletme senaryoları için kritiktir; çünkü dil modeline sadece karakter bazlı değil, anlamsal olarak en tutarlı ve rafine veri parçalarını göndermemizi sağlar.



2. Vektör Karşılaştırma Metrikleri


Vektör uzayında iki veri parçasının birbirine ne kadar "yakın" olduğunu ölçmek için üç temel matematiksel yöntem kullanılır:

Metrik	Tanım	Kullanım Alanı
Dot Product (Nokta Çarpım)	Vektörlerin hem yönünü hem de büyüklüğünü dikkate alan skaler çarpımdır.	Hem yön hem şiddet önemliyse tercih edilir.
Cosine Similarity (Kosinüs Benzerliği)	İki vektör arasındaki θ açısına odaklanır. Değer 1 ise maksimum benzerliği, -1 ise tam zıtlığı ifade eder.	RAG senaryolarında en çok tercih edilen metriktir.
Euclidean Distance (Öklid Uzaklığı)	İki nokta arasındaki gerçek geometrik mesafedir.	Koordinat bazlı kesin uzaklık gereken durumlarda kullanılır.

Cosine Similarity | Kosinüs Benzerliği

Dot Product | Nokta Çarpım


Euclidian Distance | Öklid Uzaklığı




$$\cos(\theta) = \frac{a \cdot b}{|a| \cdot |b|}$$



$$-1 \leq \cos(\theta) \leq 1$$



$$a \cdot b = |a| \cdot |b| \cdot \cos(\theta)$$



$$E(a, b) = \sqrt{(x - i)^2 + (y - j)^2}$$

3. MMR (Maximal Marginal Relevance) Algoritması

Sadece en benzer sonuçları getirmek bazen bilgi tekrarına (redundancy) yol açabilir. Örneğin, dört sonucun dördü de aynı bilgiyi farklı kelimelerle söylüyor olabilir. **MMR**, benzerlik (relevance) ile çeşitlilik (diversity) arasında bir denge kurar.

- **Çalışma Mantığı:** İlk dökümanı en yüksek benzerliğe göre seçer; ancak sonraki dökümanları seçerken hem sorguya benzemelerini hem de seçilmiş olan dökümanlara **benzememelerini** hedefler.
- **Lambda (\$\lambda\$) Katsayısı:** Bu dengenin ağırlığını belirler. \$\lambda = 0.5\$ değeri benzerlik ve çeşitlilik arasında eşit bir denge kurar.

MMR | Maximal Marginal Relevance

Girdi/Sorgu Dokümanı

k = 4

İlgili Dokümanlar



Doc #1



Girdiye Kıyasla
En Yüksek Kosinüs
Benzerliğine Sahip
Doküman

Doc #2



Girdiye Kıyasla
Yüksek Kosinüs
Benzerliği ve
Doc#1 ile Düşük
Kosinüs Benzerliği
Arasında Denge

Doc #3



Girdiye Kıyasla
Yüksek Kosinüs
Benzerliği ve
Doc#1 ve Doc#2 ile
Düşük Kosinüs
Benzerliği Arasında
Denge

Doc #4



Girdiye Kıyasla
Yüksek Kosinüs
Benzerliği ve
Doc#1, Doc#2 ve
Doc#3 ile Düşük
Kosinüs Benzerliği
Arasında Denge

MMR sayesinde dil modeline gönderilen veri kümesi çok daha geniş bir perspektif ve zengin bir "done" sunar; bu da üretilen yanıtın kalitesini doğrudan artırır.