

OLLAMA İLE YEREL (LOCAL) BÜYÜK DİL MODELLERİ ÇALIŞTIRMA

1. Yerel Inference (Local Çalıştırma) Kavramı

Yerel inference, büyük dil modellerinin (Large Language Models – LLM) herhangi bir bulut servisine, uzak sunucuya veya harici API'ye bağlanmadan, tamamen kullanıcının kendi bilgisayarında çalıştırılmasıdır. Bu yaklaşımda modelin ağırlıkları, inference süreci ve üretilen çıktılar cihaz sınırları içinde kalır.

Yerel çalıştırma yaklaşımı aşağıdaki avantajları sağlar:

- İnternet bağlantısına ihtiyaç duyulmaz
- Veri güvenliği ve gizliliği artar
- Token bazlı kullanım maliyetleri ortadan kalkar
- Gecikme (latency) minimum seviyeye iner
- Deneme ve test süreçleri hızlanır

Bu nedenle yerel inference, özellikle hassas verilerle çalışan akademik, kurumsal ve Ar-Ge projelerinde tercih edilmektedir.

2. Ollama Nedir?

Ollama, açık kaynak büyük dil modellerinin yerel ortamda çalıştırılmasını sağlayan bir model çalıştırma ve yönetim platformudur. Ollama bir model değildir; modelleri indiren, yöneten ve inference sürecini yöneten bir altyapıdır.

Ollama'nın temel özellikleri şunlardır:

- Terminal tabanlı kullanım
- Tek komutla model indirme (pull)
- Tek komutla model çalıştırma (run)
- Sohbet bağlamını (context) otomatik olarak koruma
- llama.cpp tabanlı yüksek performanslı inference
- CPU ve GPU desteği

Ollama, geliştiriciler için hızlı test ve prototipleme imkânı sunar.

3. Ollama Tarafından Desteklenen Modeller

Ollama, birçok popüler açık kaynak büyük dil modelini destekler. Bunlardan bazıları:

- Mistral
- LLaMA
- Gemma
- Phi
- Qwen
- Mixtral

Güncel ve desteklenen modellerin listesine aşağıdaki adresten ulaşılabilir:

<https://ollama.com/models>

Bu sayfa üzerinden modelin:

- Parametre sayısı
- Boyutu
- Kullanım amacı

incelenerek sistem özelliklerine uygun bir seçim yapılabilir.

4. Sistem Gereksinimleri

Yerel inference işlemleri yüksek donanım kaynakları gerektirebilir. Özellikle modelin parametre sayısı arttıkça RAM ve işlemci ihtiyacı da artar.

Minimum Önerilen Donanım

- 8 GB RAM
- Modern çok çekirdekli CPU
- SSD disk

Önerilen Donanım

- 16 GB veya üzeri RAM
- Güçlü CPU
- CUDA destekli GPU (opsiyonel ancak büyük avantaj sağlar)

Başlangıç seviyesi denemeler için **Mistral 7B** gibi daha hafif modeller tercih edilmelidir.

5. Ollama Kurulumu

5.1 Resmi Web Sitesi

Ollama yalnızca resmi web sitesi üzerinden indirilmelidir:

<https://ollama.com>

Ana sayfada Windows, macOS ve Linux için ayrı indirme seçenekleri bulunmaktadır.

5.2 Windows Üzerinde Kurulum

1. Windows için sunulan .exe dosyası indirilir
2. Dosya çalıştırılır
3. Standart uygulama kurulumu yapılır
4. Kurulum tamamlandığında Ollama arka planda servis olarak çalışır

Kurulumdan sonra Ollama yaklaşık 1–1,5 GB disk alanı kullanır (model dosyaları hariç).

6. Ollama'nın Çalıştırılması

Ollama grafik arayüz sunmaz. Tüm işlemler terminal üzerinden gerçekleştirilir.

Windows üzerinde:

- Komut İstemi (CMD)
- PowerShell
- Visual Studio Code terminali

kullanılabilir.

Ollama'nın doğru kurulduğunu kontrol etmek için terminalde aşağıdaki komut çalıştırılır:

```
ollama
```

Bu komut, Ollama'ya ait tüm kullanılabilir komutları ve kısa açıklamalarını listeler.

7. Model İndirme (Pull İşlemi)

Bir modeli yerel sisteme indirmek için pull komutu kullanılır.

Örnek: Mistral Modeli

```
ollama pull mistral
```

Bu komut:

- Modelin ağırlık dosyalarını indirir
- İndirme boyutu modele göre değişir (Mistral ~4–5 GB)
- İnternet hızına bağlı olarak birkaç dakika sürebilir

8. Yüklü Modelleri Listeleme

Sistemde yüklü olan modelleri görmek için:

`ollama list`

komutu kullanılır. Bu komut, indirilen tüm modelleri listeler.

9. Model Çalıştırma (Inference)

Bir modeli çalıştırmak için `run` komutu kullanılır.

Örnek:

`ollama run mistral --verbose`

`--verbose` parametresi sayesinde:

- Harcanan token sayısı
- Değerlendirme süresi
- Yükleme süresi

gibi performans bilgileri görüntülenir.

Bu noktadan sonra terminal, etkileşimli sohbet moduna geçer.

10. Sohbet Bağlamı (Context) Yönetimi

Ollama, aynı oturum içinde yapılan tüm etkileşimleri bağlam olarak tutar. Bu sayede:

- Önceki sorular hatırlanır
- Önceki cevaplara referans verilebilir
- Sohbet tabanlı kullanım mümkündür

Bu özellik, Ollama'yı yalnızca tek seferlik soru-cevap aracından çıkararak sohbet tabanlı bir sistem haline getirir.

11. Model Kısıtları ve Gerçekçilik

Küçük parametrelı modellerin bazı sınırlamaları vardır:

- Çok dilli yetenekler zayıf olabilir
- Güncel bilgi eksikliği (knowledge cutoff)
- Karmaşık muhakeme hataları

Bu durum, modelin yetersizliğinden değil; parametre sayısı ve eğitim verisi sınırlarından kaynaklanır.

12. Yerel Çalışmanın Maliyet ve Güvenlik Avantajları

12.1 Maliyet

Bulut tabanlı sistemlerde token başına ücretlendirme yapılırken, yerel çalışmada:

- Token maliyeti yoktur
 - API çağrısı ücreti yoktur
 - Tek maliyet donanım ve elektrik tüketimidir
-

12.2 Güvenlik

Yerel inference senaryosunda:

- Veriler cihaz dışına çıkmaz
 - Hassas bilgiler üçüncü taraflara gönderilmez
 - KVKK ve GDPR gibi regülasyonlar açısından avantaj sağlar
-

13. Python ile Ollama Entegrasyonu

Ollama, arka planda yerel bir HTTP servisi olarak çalışır. Bu servis Python üzerinden REST API ile kullanılabilir.

Örnek Python Kullanımı:

```
import requests

url = "http://localhost:11434/api/generate"

payload = {
    "model": "mistral",
    "prompt": "Yapay zeka nedir?",
    "stream": False
}

response = requests.post(url, json=payload)
print(response.json()["response"])
```

Bu yapı sayesinde:

- Backend uygulamaları
- Veri bilimi projeleri
- Akademik deneyler

yerel LLM'lerle entegre edilebilir.

4. Ollama ve LM Studio Karşılaştırması

LM Studio, grafik arayüz tercih eden kullanıcılar için bir alternatiftir. Ancak Ollama:

- Daha esnektir
- Otomasyona uygundur
- Backend entegrasyonları için daha güçlüdür

Geliştirici odaklı projelerde Ollama tercih edilir.

15. Genel Değerlendirme

Ollama, yerel büyük dil modeli çalıştırma sürecini sadeleştiren güçlü bir araçtır. Yerel inference yaklaşımı; hız, maliyet ve güvenlik açısından önemli avantajlar sunar. Doğru model seçimiyle, birçok üretken yapay zekâ senaryosu yerel ortamda başarıyla gerçekleştirilebilir.