

BAŞLIK: PEKİŞTİRMELİ ÖĞRENME (REINFORCEMENT LEARNING): GENEL TEKRAR SORULARI

TÜR: Çoktan Seçmeli Değerlendirme (Sorular 21.1 - 21.3 konularını kapsar)

SORULARIN CEVAPLARI EN ALTTA BULUNMAKTADIR.

1. Pekıştirmeli öğrenmeyi, gözetimli öğrenmeden en temel şekilde ayıran özellik nedir?

- A) Pekıştirmeli öğrenme yalnızca oyunlarda kullanılabilir.
- B) Gözetimli öğrenme sadece görüntülerle çalışır.
- C) Pekıştirmeli öğrenmede sabit bir doğru cevap etiketi yoktur; ajan kendi deneyimini üretir ve gecikmeli bir ödül sinyalinde öğrenir.
- D) Pekıştirmeli öğrenmede veri seti hiç kullanılmaz.

2. Bir pekıştirmeli öğrenme probleminde "ajan" (agent) neyi ifade eder?

- A) Ödül fonksiyonunu.
- B) Ortamın kendisini.
- C) Karar veren ve öğrenen taraftır.
- D) Veri setindeki etiketleri.

3. Bir MDP (Markov Karar Süreci) beşli demeti (S, A, P, R, γ) içinde γ neyi temsil eder?

- A) Öğrenme oranını.
- B) Gelecekteki ödüllerin bugünkü değerini belirleyen indirim faktörünü.
- C) Eylem sayısını.
- D) Durum uzayının boyutunu.

4. "Markov Özelliği" (Markov Property) ne anlama gelir?

- A) Ödüllerin her zaman pozitif olması gerektiği.
- B) Eylemlerin her zaman deterministik sonuç vermesi.
- C) Geleceğin sadece şu anki duruma bağlı olduğu, geçmişten bağımsız olduğu varsayımı.
- D) Ajanın hafızasının sınırsız olduğu.

5. Keşif (Exploration) ile Sömürü (Exploitation) arasındaki denge neden önemlidir?

- A) Keşif her zaman gereksizdir, sadece sömürü yeterlidir.
- B) Sadece sömürü yapan bir ajan yerel olarak iyi ama global olarak optimal olmayan bir stratejide sıkışabilir; sadece keşif yapan bir ajan öğrendiklerini hiç kullanamaz.
- C) Sadece hesaplama hızını artırmak için önemlidir.
- D) İkisi arasında hiçbir fark yoktur.

6. ϵ -greedy (epsilon-açgözlü) stratejide epsilon (ϵ) değeri eğitim ilerledikçe genellikle nasıl değişir?

- A) Rastgele deęiřir.
- B) Kademeli olarak azaltılır (epsilon decay), böylece ajan zamanla daha çok sömürü yapar.
- C) Kademeli olarak artırılır (epsilon growth).
- D) Sabit kalır.

7. Q-Learning algoritmasında $Q(s,a)$ fonksiyonu neyi ifade eder?

- A) s durumunda a eylemi yapıp sonrasında en iyi şekilde davranılırsa beklenen toplam indirgenmiş ödölü.
- B) s durumunda a eylemi seçilirse elde edilecek anlık ödölü.
- C) Ortamın geçiř olasılıęını.
- D) Politikanın rastgelelik derecesini.

8. Q-Learning güncelleme formölünde α (alfa) parametresi neyi kontrol eder?

- A) Keřif oranını.
- B) Epizot sayısını.
- C) İndirim faktörünü.
- D) Yeni gözlemlenen bilgiye ne kadar aęırlık (öęrenme oranı) verileceęini.

9. Q-Learning'deki "TD hatası" (Temporal Difference Error) neyi ölęer?

- A) Gözlemlenen ödöl + indirgenmiş gelecek tahmini ile mevcut $Q(s,a)$ tahmini arasındaki farkı.
- B) Ortamdaki durum sayısını.
- C) Politikanın rastgelelik derecesini.
- D) Modelin eęitim süresini.

10. Optimum politika $\pi^*(s)$, öęrenilmiş bir Q-tablosundan nasıl türetilir?

- A) O durumda en düşük Q-deęerine sahip eylem seęilerek.
- B) Q-tablosu politika türetmek için kullanılamaz.
- C) O durumda en yüksek Q-deęerine sahip eylem seęilerek (argmax).
- D) O durumdaki rastgele bir eylem seęilerek.

11. FrozenLake ortamında "is_slippery=True" ayarının anlamı nedir?

- A) Ödölün her adımda verildięi.
- B) Ajanın asla hedefe ulaşamayacaęı.
- C) Ortamın deterministik olduęu, seęilen eylemin her zaman istenen yönde hareket ettirdięi.
- D) Buzun kaygan olması nedeniyle seęilen eylemin bir olasılıkla farklı bir yönde sonuçlanabildięi (stokastik geçiř).

12. Tablo tabanlı Q-Learning'in, CartPole gibi sürekli (continuous) durum uzaylı ortamlarda doğrudan kullanılamamasının temel nedeni nedir?

- A) Sürekli durum uzayında sonsuz sayıda olası durum olduęu için bir tabloda tüm durumlar tutulamaz.
- B) Q-Learning yalnızca görüntü tabanlı ortamlarda ęalışır.
- C) CartPole'da ödöl fonksiyonu tanımsızdır.

D) CartPole'da eylem uzayı yoktur.

13. Politika gradyanı (policy gradient) yöntemleri, Q-Learning'den temel olarak nasıl farklıdır?

- A) Bir değer tablosu/fonksiyonu yerine politikayı $\pi(a|s)$ doğrudan parametrik olarak öğrenirler.
- B) Yalnızca ayırık eylem uzaylarında çalışabilirler.
- C) Ödül fonksiyonu kullanmazlar.
- D) Keşif yapmalarına hiç gerek yoktur.

14. REINFORCE algoritmasının güncelleme kuralında G_t terimi neyi temsil eder?

- A) Politikanın parametre sayısını.
- B) Öğrenme oranını.
- C) İndirim faktörünün karesini.
- D) O andan itibaren epizot sonuna kadar elde edilen toplam indirgenmiş ödülü (getiri).

15. REINFORCE neden "Monte Carlo" bir yöntem olarak sınıflandırılır?

- A) Q-Learning ile birebir aynı olduğu için.
- B) Güncellemeyi yapmak için epizotun tamamen bitmesini ve gerçek toplam getiriye (G_t) beklediği için, tek adımlık bootstrapping yapmadığı için.
- C) Rastgele sayı üretmediği için.
- D) Sadece kumar ortamlarında kullanıldığı için.

16. DQN (Deep Q-Network) mimarisinde "Deneyim Tekrarı" (Experience Replay) ne işe yarar?

- A) Ajanın hiç deneyim biriktirmeden öğrenmesini sağlar.
- B) Sadece test aşamasında kullanılır.
- C) Ödül fonksiyonunu otomatik olarak tasarlar.
- D) Ardışık deneyimler arasındaki korelasyonu kırmak için geçmiş deneyimleri bir havuzda biriktirip rastgele örnekler.

17. DQN'de "Hedef Ağ" (Target Network) kullanmanın amacı nedir?

- A) Yalnızca görüntü işlemek için ek bir ağ eklemek.
- B) Bellman hedefinin çok sık değişmesini önleyerek eğitimi kararlı hale getirmek.
- C) Keşif oranını otomatik ayarlamak.
- D) Eğitimi hızlandırmak için ağırlıkları rastgele başlatmak.

18. Büyük dil modellerinin (LLM) insan geri bildirimiyle ince ayarlanması (RLHF) hangi pekiştirmeli öğrenme kavramıyla doğrudan ilişkilidir?

- A) RLHF'in pekiştirmeli öğrenmeyle hiçbir ilgisi yoktur.
 - B) Tablo tabanlı Q-Learning ile; RLHF her zaman bir Q-tablosu kullanır.
 - C) Yalnızca gözetimsiz öğrenmeyle ilişkilidir.
 - D) Politika gradyanı yöntemleriyle (örn. PPO); insan tercihlerinden üretilen ödül sinyaliyle politika ince ayarlanır.
-

19. Bir ajanın ödöl fonksiyonu kötü tasarlanırsa (örn. istenmeyen bir kısayolu ödüllendirirse) ortaya çıkabilecek soruna ne ad verilir?

- A) Epsilon decay.
- B) Overfitting.
- C) Reward hacking (ödölü istismar etme).
- D) Gradient vanishing.

20. Bir robot kolunun eklem açılarını sürekli bir aralıkta (örn. -90° ile $+90^\circ$ arası herhangi bir değer) belirlemesi gerektiğinde, hangi yaklaşım tablo tabanlı Q-Learning'e göre daha uygundur?

- A) Politika gradyanı / DQN gibi fonksiyon yaklaşıklamalı yöntemler, çünkü sürekli/büyük durum-eylem uzaylarında genelleme yapabilirler.
- B) Tablo tabanlı Q-Learning, çünkü her zaman en hızlısıdır.
- C) Hiçbiri, bu tür problemler makine öğrenmesiyle çözülemez.
- D) Yalnızca gözetimsiz kümeleme yöntemleri.

CEVAP ANAHTARI

1-C 2-C 3-B 4-C 5-B 6-B 7-A 8-D 9-A 10-C 11-D 12-A 13-A 14-D 15-B 16-D 17-B 18-D 19-C 20-A